podlodka

AI Crew
12 - 16 октября

Мультиагентные системы

Михаил Мужаровский
EXANTE, Lead AI Engineer

Демо-сессия
Codey: как задача из Jira превращается в проверенный MR



rwb Selectel

EXANTE
Next Generation Investment Company

Codey: как задача из Jira превращается в проверенный MR

Автономный пайплайн на боевых системах компании: как устроен, что получилось и что из этого можно собрать у себя

PODLODKA AI CREW #4

Михаил Мужаровский
muzm@exante.eu

октябрь 2026



Михаил Мужаровский

Lead AI Engineer, EXANTE

- в EXANTE больше пяти лет
- последние два года — ИИ-направление: помогаю командам внедрять ИИ в работу
- участвую во всех ИИ-продуктах компании
- с февраля 2026 фултайм на Codey: долго один, сейчас вдвоём

Где это работает

EXANTE
Next Generation Investment Company

финтех, брокерская платформа

- торговая инфраструктура: много сервисов и стеков; там, где деньги, цена ошибки высокая
- **больше 120 разработчиков**, почти все работают удалённо из разных стран
- вся работа идёт через Jira и Slack, туда Codey и встроен

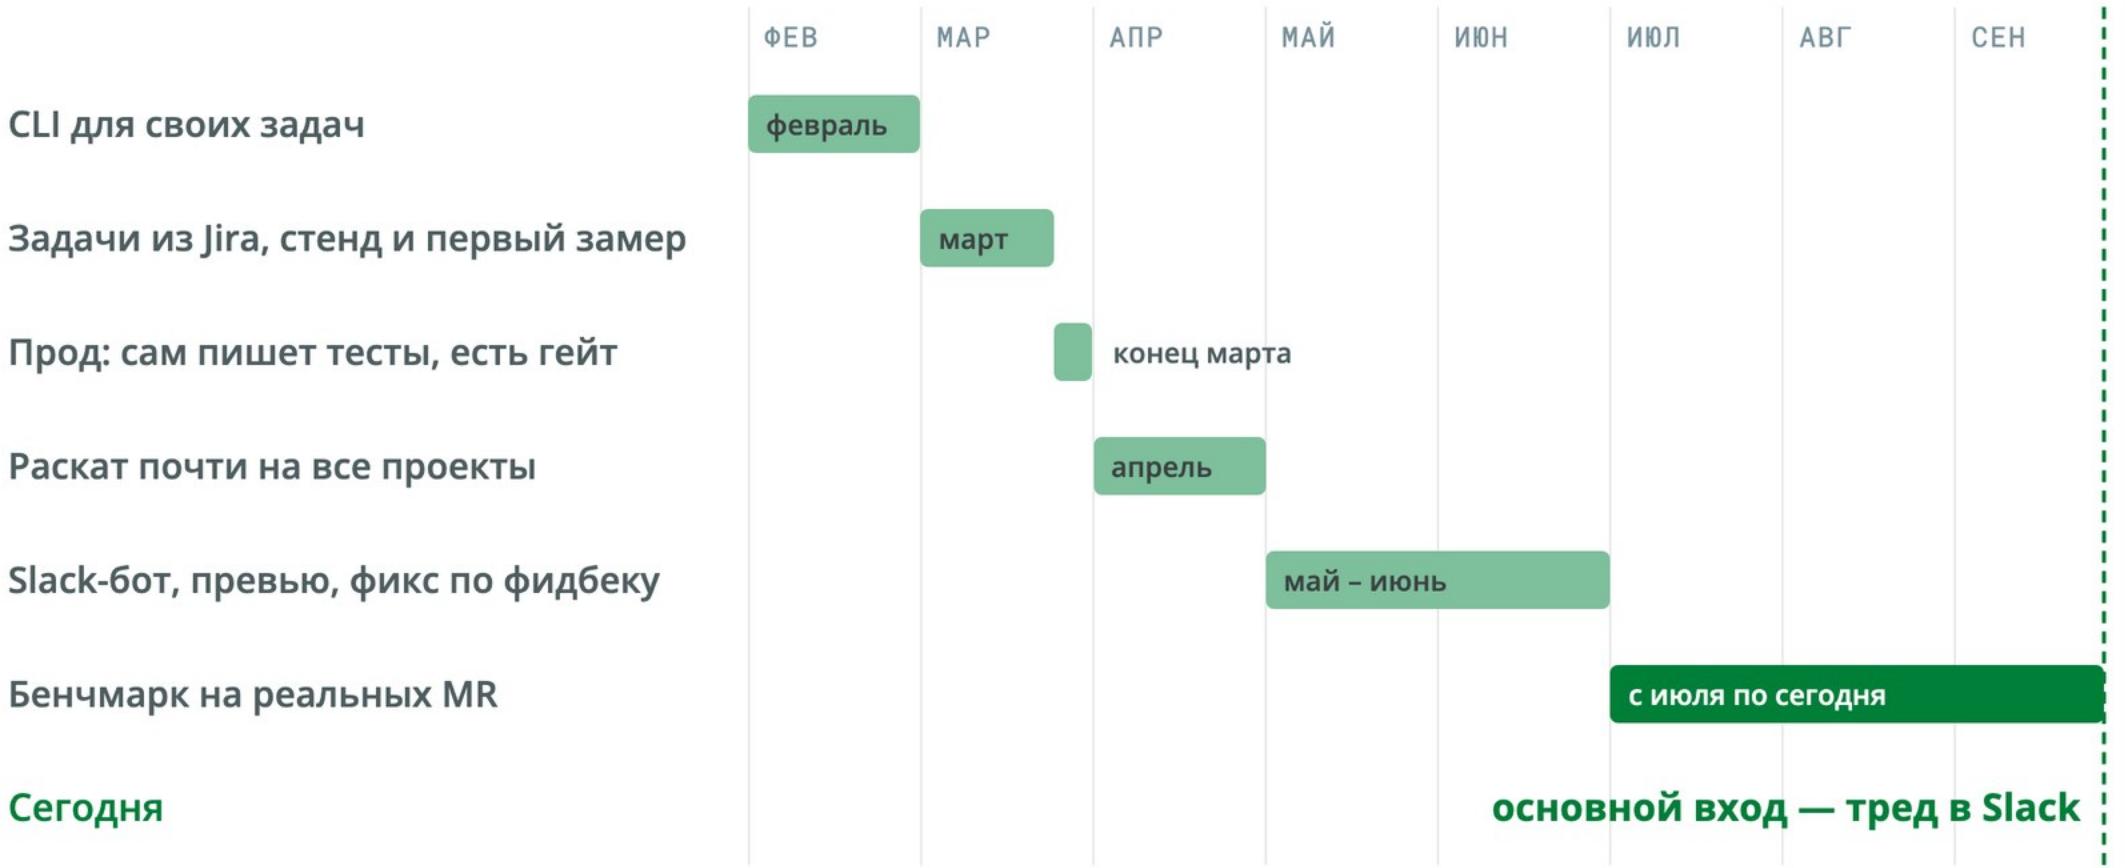
Что за проект

Codey — внутренний пайплайн задач

- берёт задачу из Jira или Slack и доводит до merge request с проверками
- подключено **16** проектов / **51** репозиторий
- в разработке **с февраля 2026**; собственный бенчмарк вместо веры на слово

От CLI для своих задач до сервиса компании

с февраля 2026 · фултайм · долго один, сейчас вдвоём



Первый замер: принял ли разработчик результат

18%

задач получили апрув разработчика

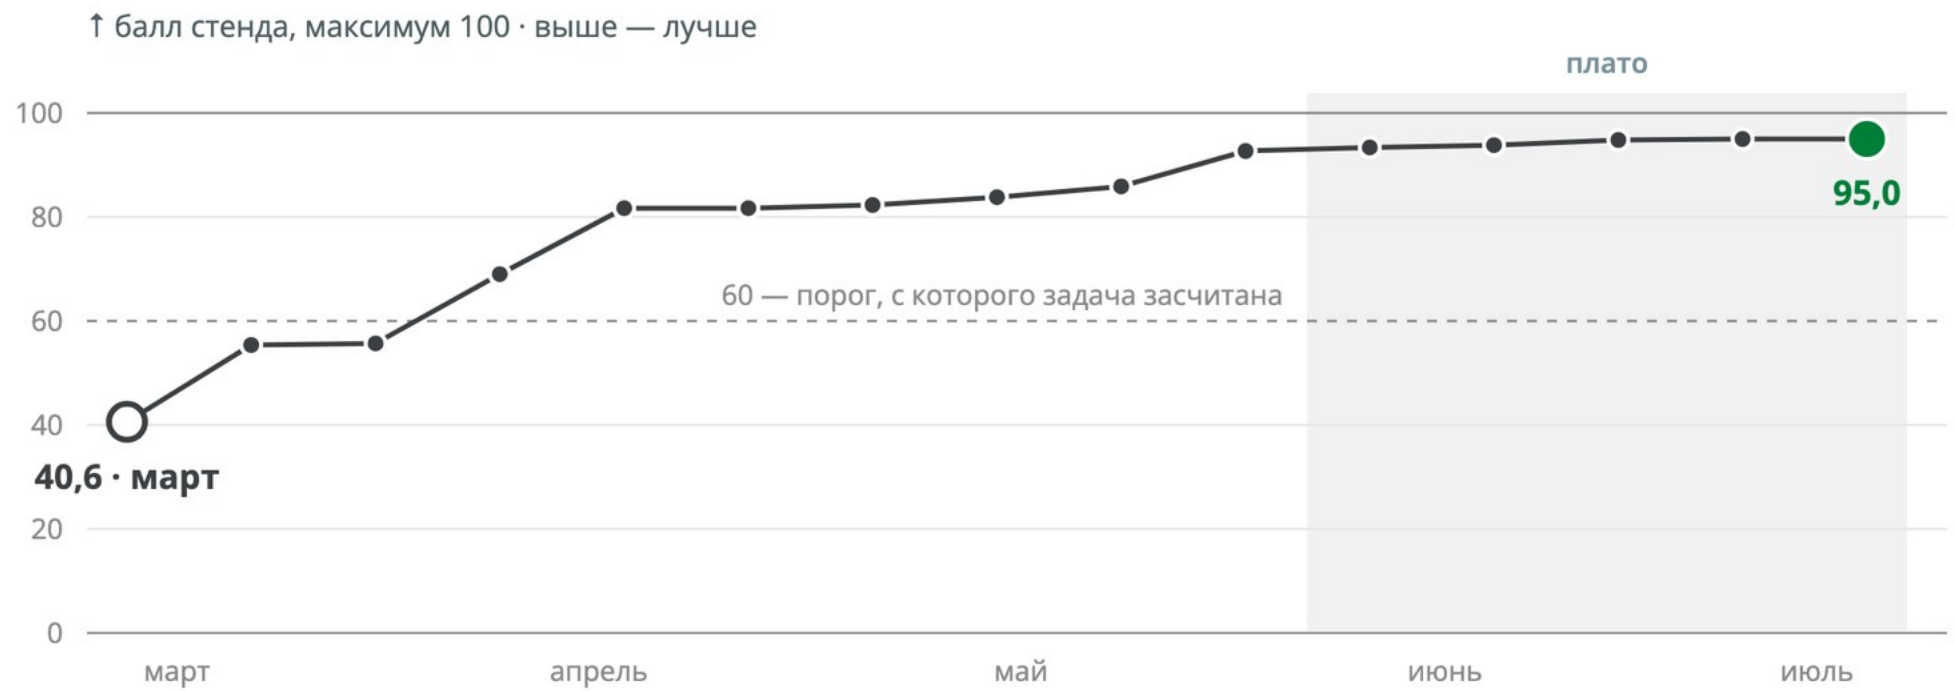
ЧТО МЕРЯЕТ ЭТА ЦИФРА

Задача прошла все стадии, бот открыл MR, разработчик посмотрел его и дал апрув.

март 2026 · 77 прогонов · реальные задачи из бэклога

Пайплайн научился доезжать: 40 → 95 из 100

балл стенда, максимум 100 · синтетические задачи, считает скрипт без модели · март → июль 2026



30	прогон дошёл до конца	+	30	линт и тесты зелёные	+	25	тронуты нужные файлы	+	15	время прогона	=	100	максимум шкалы

Три входа — один выход



Codey живёт в обычном треде



1. задача из контекста треда — никто не заполняет формы
2. карточка Jira — сразу в текущий спринт
3. вопросы по коду и API — Swagger 15 сервисов под рукой
4. оценка задачи разбором файлов, а не числом с потолка
5. статус, диагностика, перезапуск CI — кнопками в треде

Что бот делает из одной строки

ТРЕД В SLACK

Аня 14:02
на форме лимитов не влезает кнопка экспорта, клиенты жалуются

Михаил 14:04
да, и пусть сортировка по дате сохраняется. @Codey займись

Codey 14:04
Понял так: кнопка экспорта на форме лимитов не помещается, и сортировку по дате нужно запоминать. Уточню одно: после перезагрузки страницы тоже?

Михаил 14:05
да

ЧТО СОБРАЛ CODEY

Draft задачи хранится в треде, дополняется по ходу разговора

ПРОЕКТ	TASK
РЕПОЗИТОРИЙ	`frontend-app` выбрал сам по коду
ЗАГОЛОВОК	Кнопка экспорта на форме лимитов и сохранение сортировки
ОПИСАНИЕ	**Результат:** кнопка экспорта видна целиком, выбранная сортировка по дате сохраняется **Готово, когда:** кнопка не обрезается, после перезагрузки сортировка та же уточнил в треде

Create ✏️ Fill in Cancel

Откуда агент знает, где форма лимитов

ПРО ПРОЕКТ И КОД

Профайл проекта
раз в неделю бот сканирует репы: архитектура, коммиты, тесты

Скиллы
свои под проект, из самой репы и общие для всех проектов

Сам код
планировщик читает репы, прежде чем строить план

«поменяй на форме лимитов»

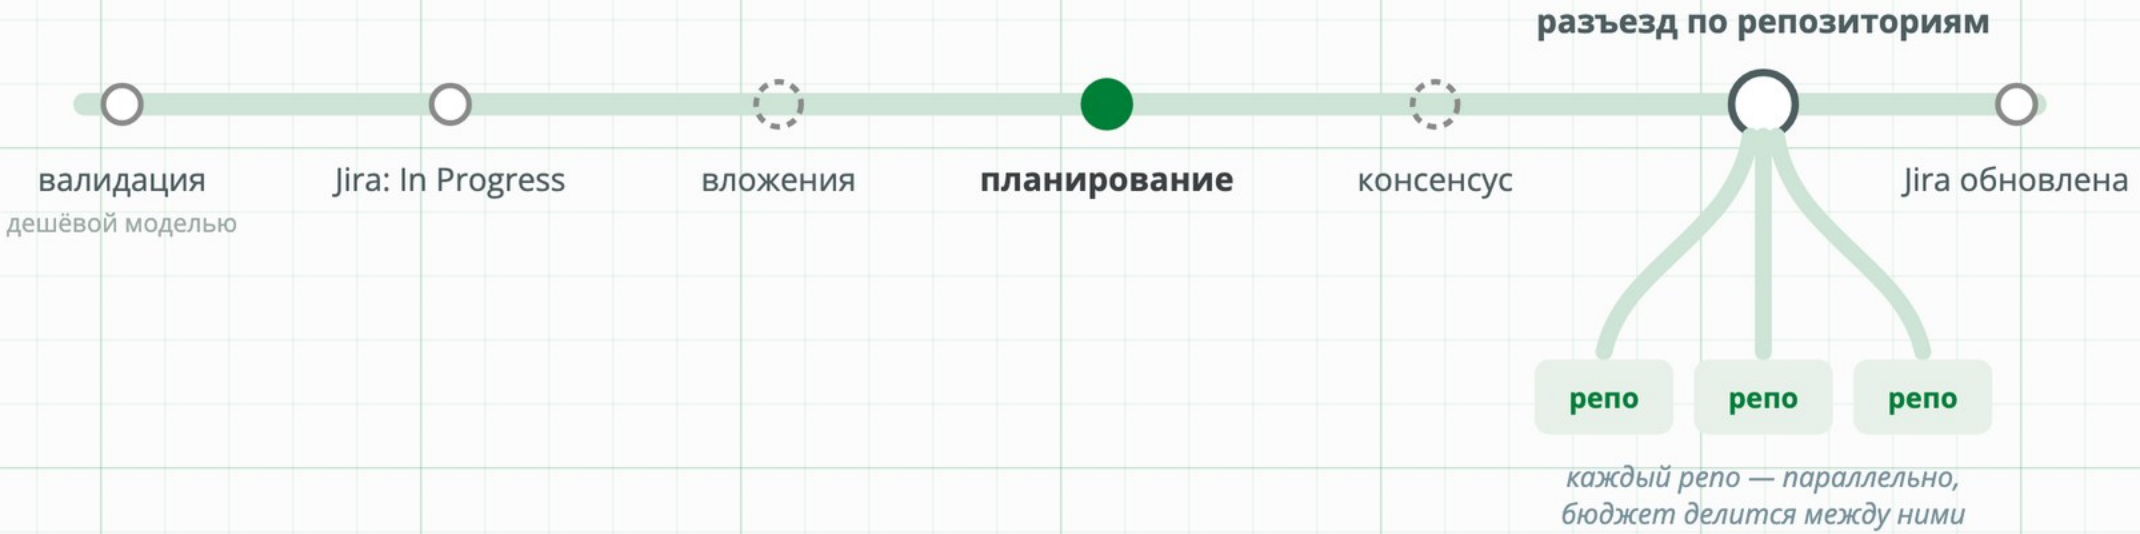
ВОКРУГ ЗАДАЧИ

Карточки Jira
поиск по карточкам: что в компании зовут формой лимитов

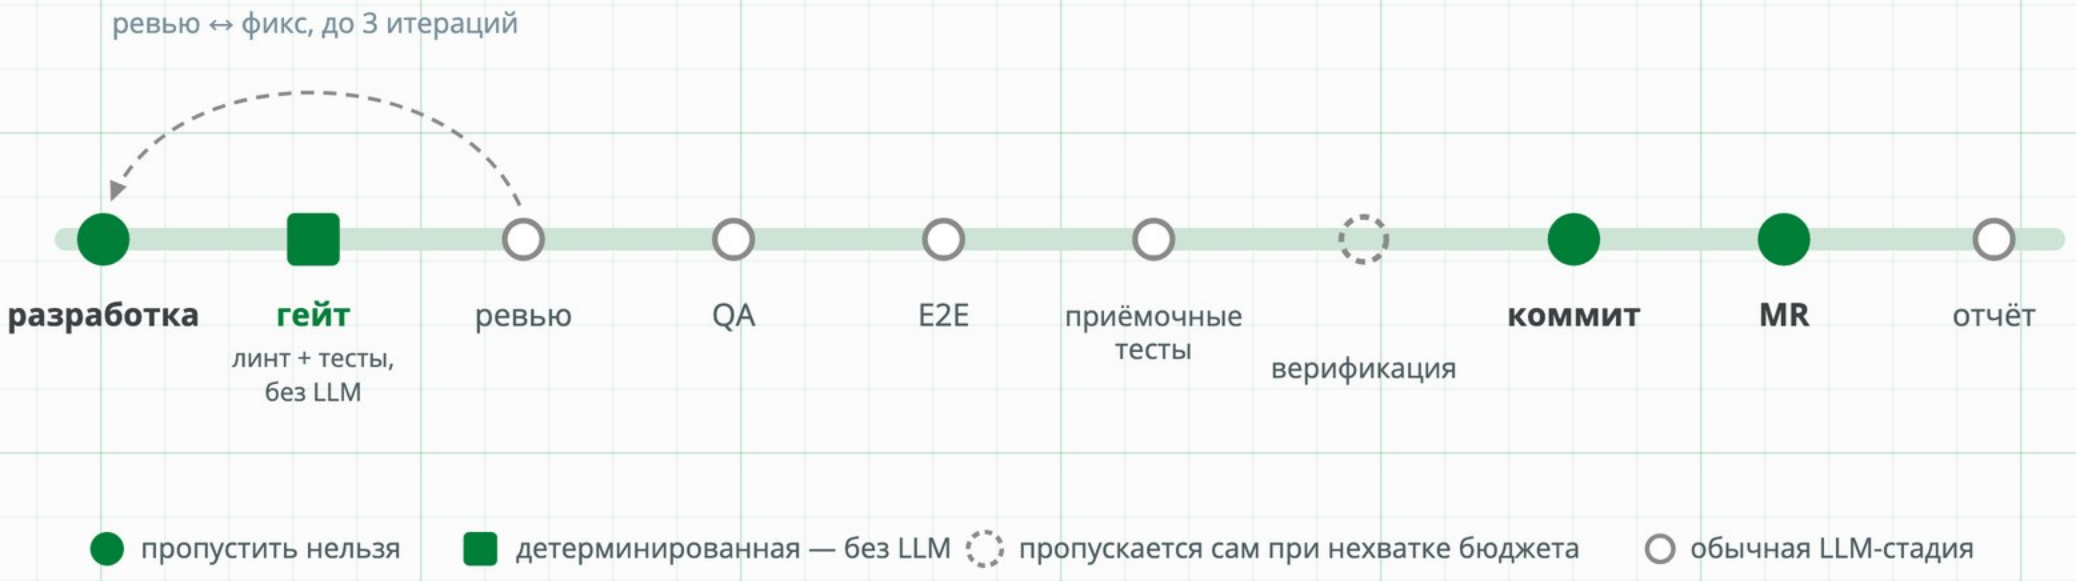
Swagger
API пятнадцати сервисов компании под рукой

Вложения и Figma
скриншоты и макеты из задачи скачиваются на старте

Что происходит с задачей



Что происходит в каждом репозитории



Гейт качества: единственная стадия без модели



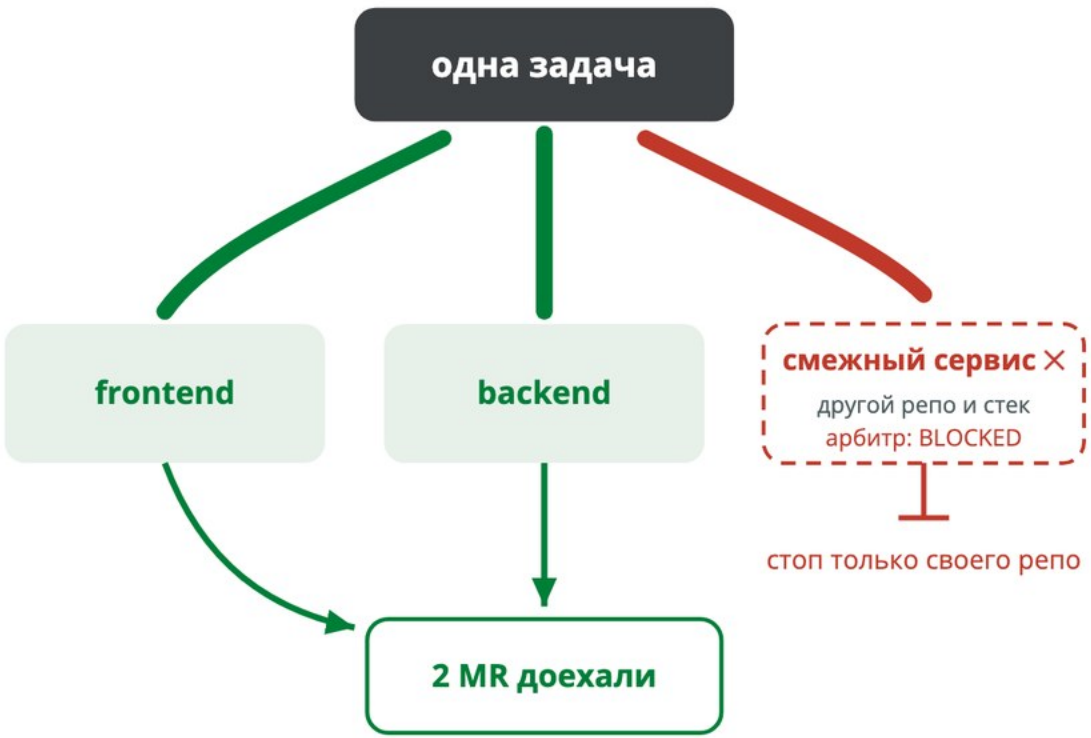
Чей это красный тест?

- красный **и на базовой ветке** → не вина агента, идём дальше
- зелёный на базовой, красный в прогоне → **сломал агент, чинить**

Гейт и ревью прогон не останавливают. Останавливает только **арбитр** — и у него три вердикта:

PASS → к MR **DEGRADED** → к MR с пометкой Known Gaps **BLOCKED** → стоп, MR не открывается

Одна задача — несколько репозиториев



- задача **разъезжается по репозиториям параллельно**: фронт, бэк, смежный сервис
- у каждого **свои 10 стадий**: разработка, гейт, ревью, свой MR
- падение одного **не отменяет соседей**: два MR доехали, третий — в фикс-очередь

Начиналось с пары фронт + бэк внутри одного продукта. Сейчас одна задача тянет **разные проекты одним прогоном** — так делаются эпики.

23 роли: у каждой свой промпт, инструменты и модель

МОДЕЛЬ НА РОЛЬ · СЕЙЧАС В ПРОДЕ

План и код	**GPT Astra**
Ревью	**Opus 5**
QA и верификатор	**GPT-6 Sol**
Консенсус	**выключен**

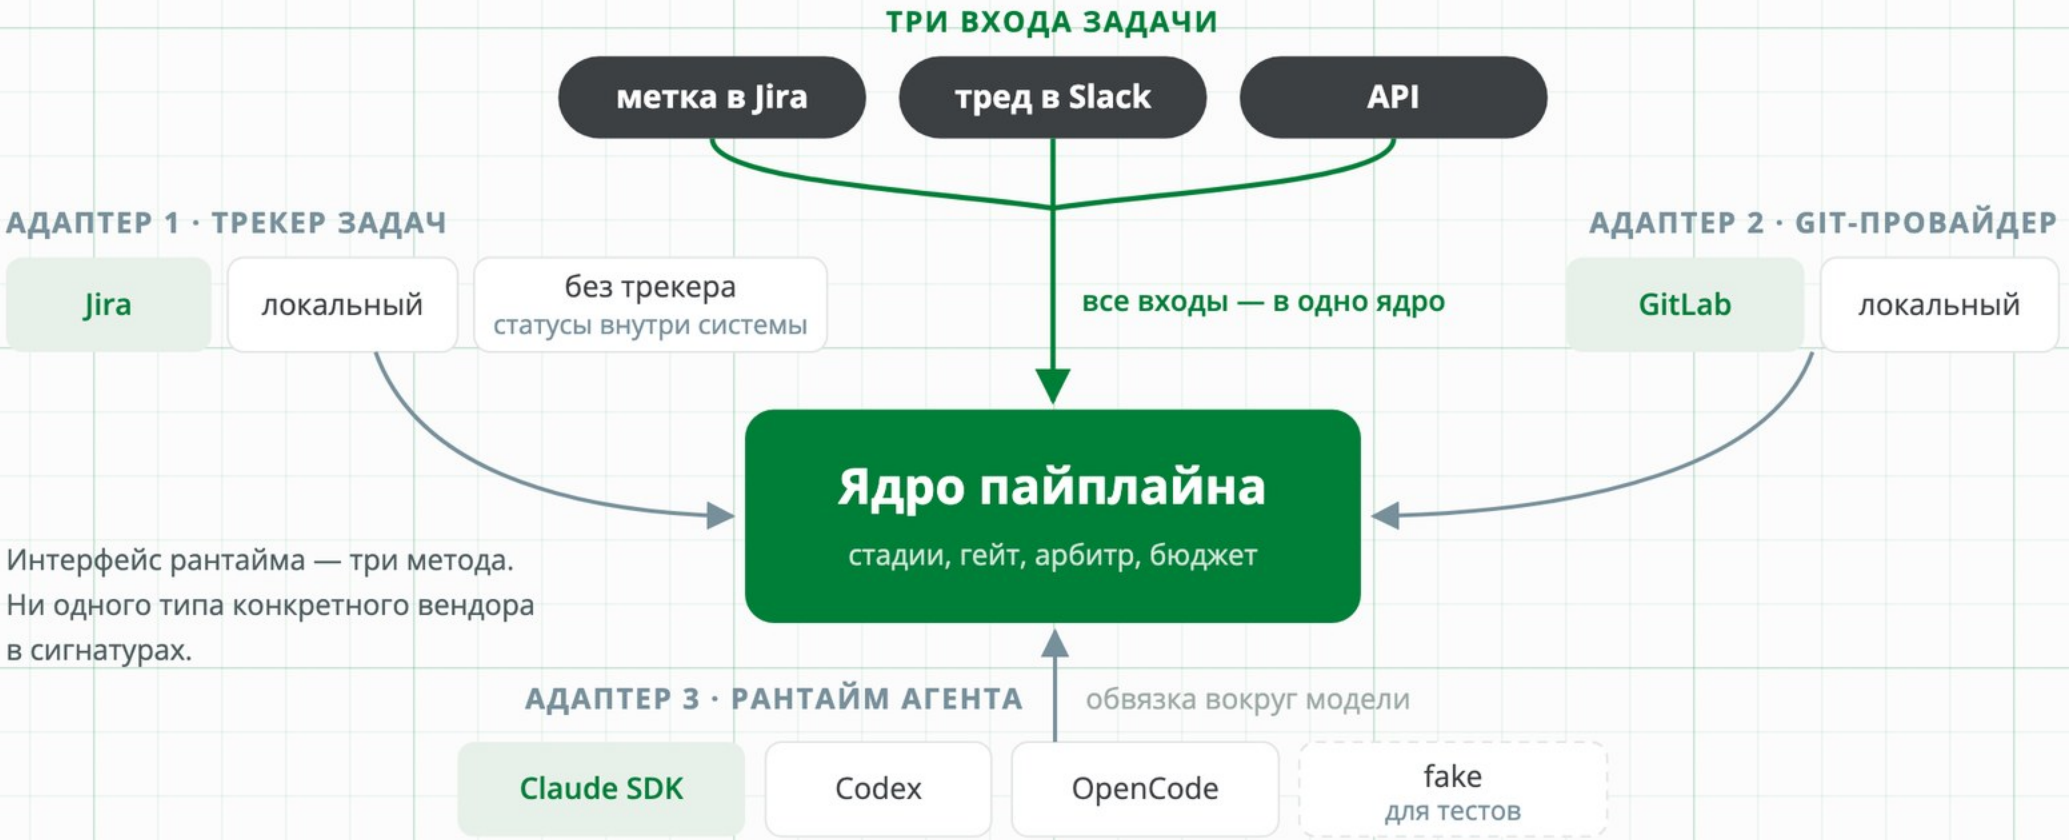
планировщики отдельных реп лезли в чужие репы → **один планировщик на всю задачу**

деньги уходили на задачи, описанные непонятно → **дешёвый валидатор до дорогих стадий**

агенты блокировали друг друга, прогон зависал → **арбитр — единственный, кто может остановить**

Самые умные модели во все роли (тогда Opus 4.8): начали спорить, хуже держали план, дифф разросся. **Как я это мерил — в блоке про замеры.**

Ядро отдельно, к нему три адаптера



Как часто Codey просыпается и где держит состояние

РИТМ РАБОТЫ **Slack присылает события сам, Jira и GitLab — поллингом**

КАК ЧАСТО	КТО	ЧТО ДЕЛАЕТ
сразу	**бот в Slack**	Slack сам присылает событие: тег, реплика в треде, кнопка
раз в минуту	**демон**	поллингом смотрит трекер: появились ли новые метки
15–30 минут	**прогон**	одна задача от метки до MR
раз в несколько минут	**монитор**	проверяет открытые MR: упал ли CI, есть ли треды ревью
пока идёт сборка	**бот в Slack**	пишет статус в тред: «сделал фикс, жду сборку превью»

Состояние в Postgres

по каждой задаче: ветка, MR, чекпоинты стадий

Три попытки

на четвёртой метка «ai-failed», дальше задачу ведёт человек

Что получает ревьюер

DRAFT **TASK-123 · Кнопка экспорта на форме лимитов + сохранение сортировки**

ПЛАН И ЧТО СДЕЛАНО

- кнопка экспорта вынесена в тулбар формы, не перекрывается на узких экранах
- сортировка по дате сохраняется в параметрах запроса
- добавлены юнит-тесты и e2e-сценарий на экспорт

⚠ KNOWN GAPS — ОГОВОРКИ АРБИТРА

- e2e-сценарий пропущен: фикстура окружения не поднялась за таймаут — вердикт DEGRADED

⚠ ПРЕДУПРЕЖДЕНИЯ QA / E2E / ПРИЁМОЧНЫХ ТЕСТОВ

- QA: не проверен экспорт пустого списка

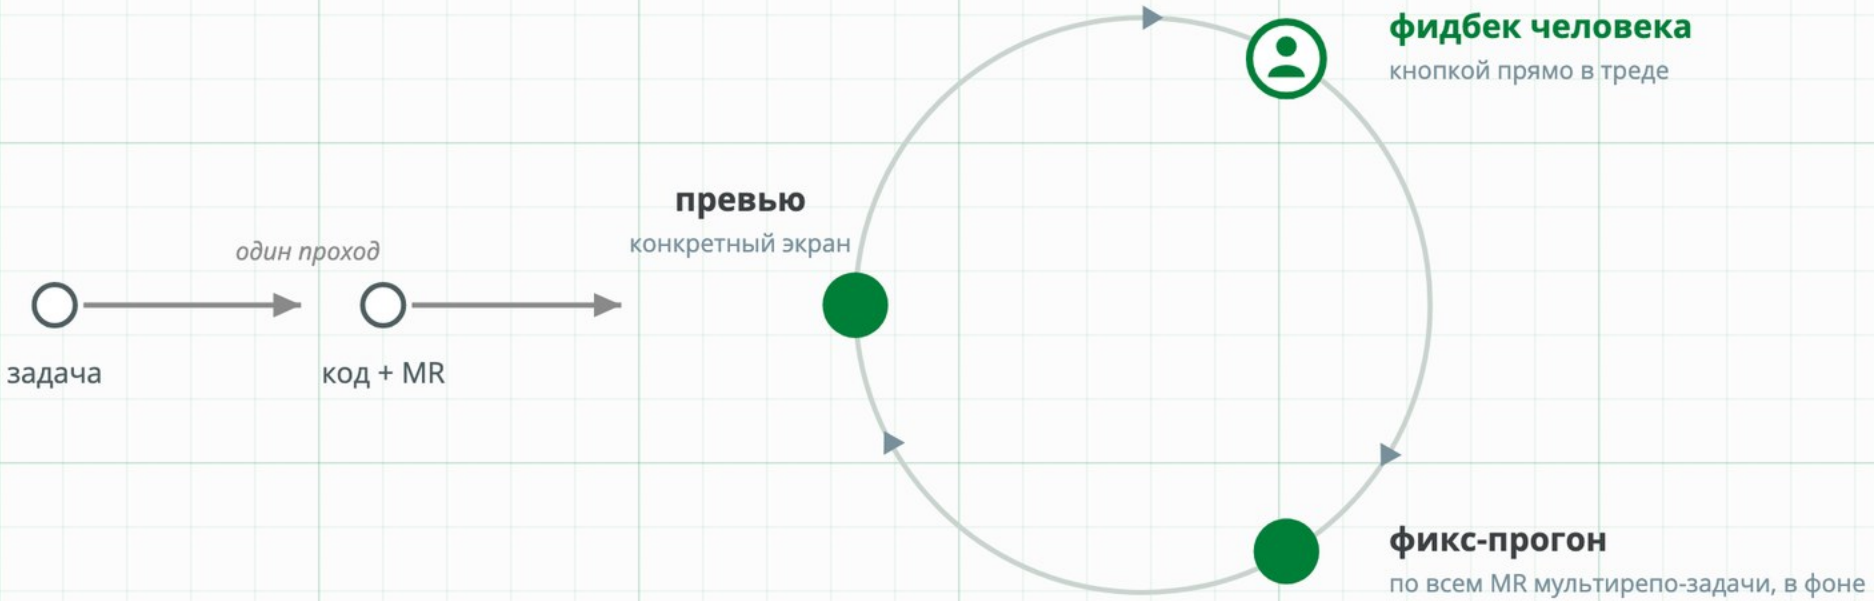
ССЫЛКИ

превью экрана · прогон #4821 — стоимость, время, логи стадий

1. ключ задачи в заголовке — MR находится из Jira и из Slack
2. план и что по нему сделано — не надо восстанавливать по диффу
3. Known Gaps — всё, что арбитр пропустил с оговоркой
4. предупреждения проверок, которые прогон не блокируют
5. превью экрана, ссылка на прогон, стоимость и время

Draft — когда есть оговорки. По умолчанию MR смотрит человек, а на части проектов — **бот-ревьюер без человека**.

Фидбек человека — часть пайплайна



Пока MR открыт, бот за него отвечает

1

Сверка с GitLab

раз в несколько минут монитор сверяет открытые ботовые MR, закрытые забывает

2

Находит проблемы

упавший CI, неразобранные треды ревью

3

Запускает починку

фикс-прогон по каждой найденной проблеме, в фоне

4

Не зацикливается

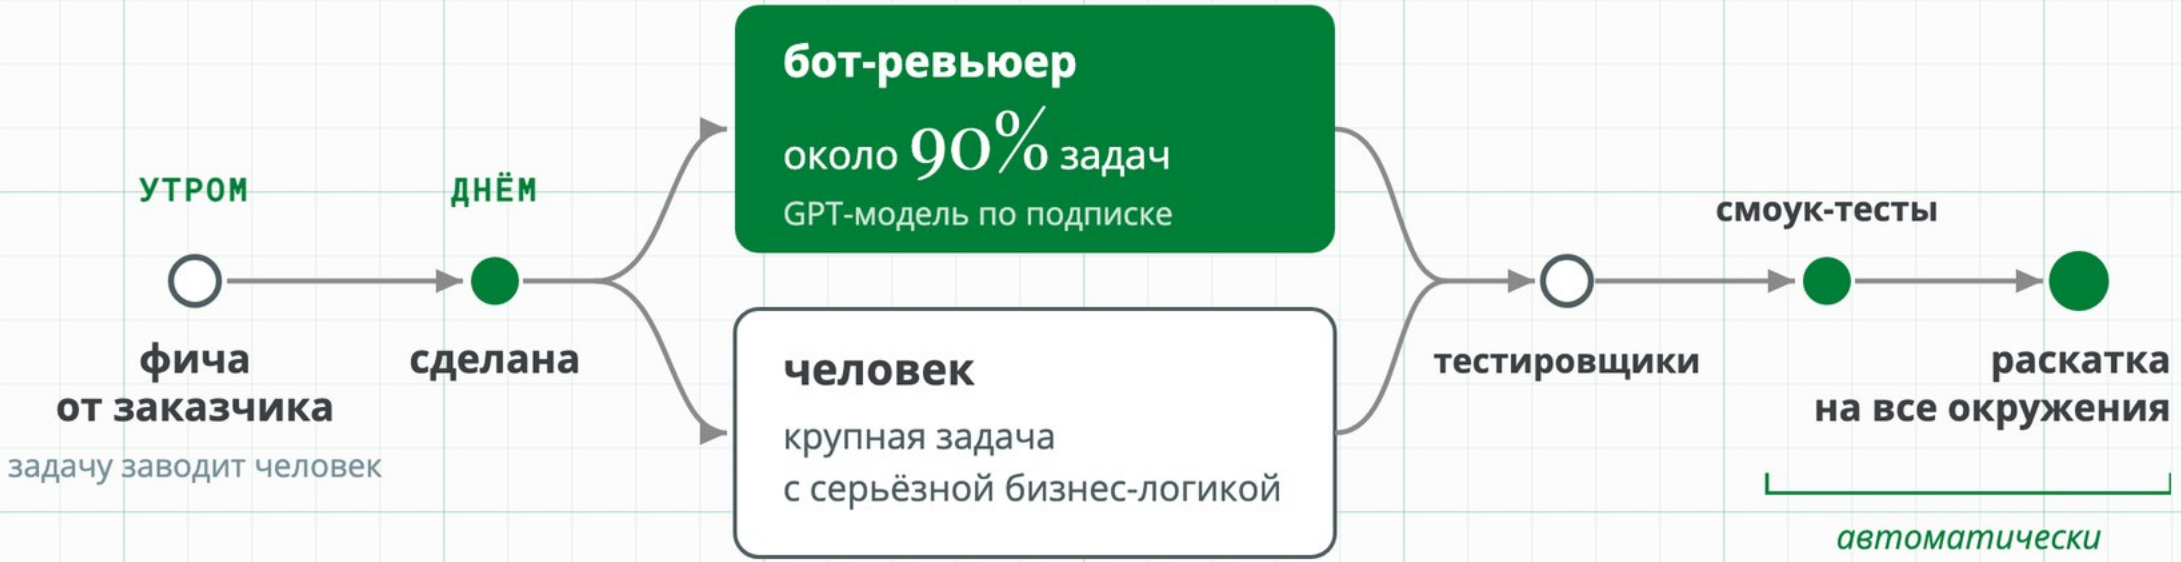
сетевую проблему не чинит по кругу: отпишется в MR один раз

ДВЕ ЗАЩИТЫ ОТ ЦИКЛА

Человек закоммитил в MR	бот в этом MR больше не работает и пишет об этом
Комментарий другого бота	берёт в работу, только если человек в треде подтвердил

Быстрый деплой упёрся в ревью

ПОКА НА ЧАСТИ ПРОЕКТОВ — САМЫХ «ГОРЯЧИХ», В ОСНОВНОМ ВНУТРЕННИХ



Без человека-ревьюера пока пробуем на части проектов:
проще выкатить, поймать баг и исправить в тот же день, чем ревьюить каждую задачу.

Бот разбирает эпик до того, как брать задачи



Сначала искали задачи, которые можно отдать агенту. **Хотим наоборот: искать задачи, которые нужно оставить людям.**

Что получилось в цифрах

Рутинные фиксы почти полностью перевели на автономный пайплайн,
а разработчики подключаются на сложных задачах

$1–5

и 15–30 минут на задачу от тикета до MR

одна задача — несколько репозиториев

и проектов одним прогоном: так делаются эпики

Slack

стал основным входом: тег в треде вместо тикета

Стенд у потолка, а до цели по задачам далеко

три шкалы · апрувы в MR · балл стенда из 100 · доля решённых задач

АПРУВЫ · УЖЕ ВИДЕЛИ

Принял ли разработчик результат?

18%

задач получили апрув
март 2026 · 77 прогонов

судит разработчик в MR

живые задачи из бэклога

БАЛЛ СТЕНДА · УЖЕ ВИДЕЛИ

Доезжает ли пайплайн до конца?

40 → 95

баллов из 100, максимум шкалы
10 синтетических задач

судит скрипт, без модели

СЛОЖНАЯ ВЫБОРКА · ДАЛЬШЕ

Решает ли задачи, на которых уже сбоил?

0,375

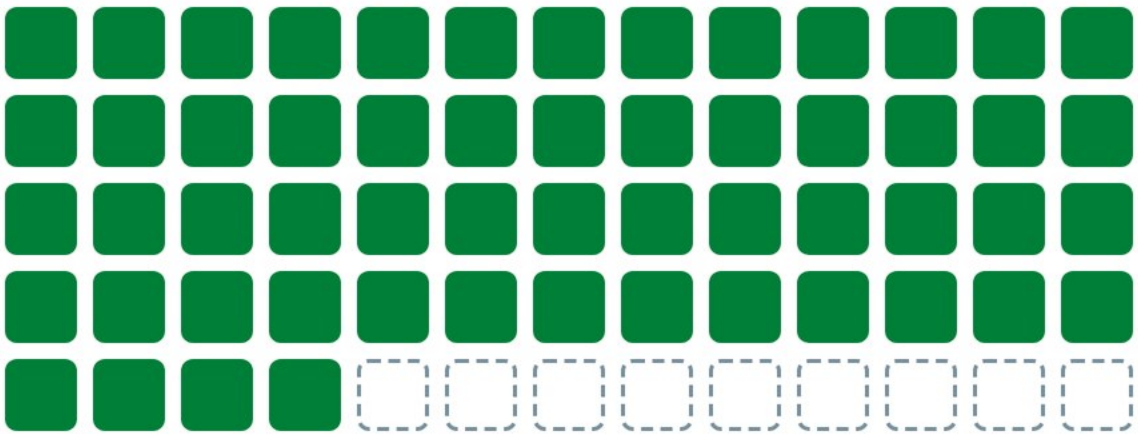
доля решённых задач на старте
при цели 0,8

судит жюри из трёх семейств моделей

У каждой задачи выборки есть ответ человека

состав сложной выборки · 65 задач из настоящих MR, 8 стеков

65 ЗАДАЧ ИЗ НАСТОЯЩИХ MR



- 56 задач: решение агента сравнивается с диффом человека
- 9 контрольных пар: дифф бота против диффа человека, проверяют жюри

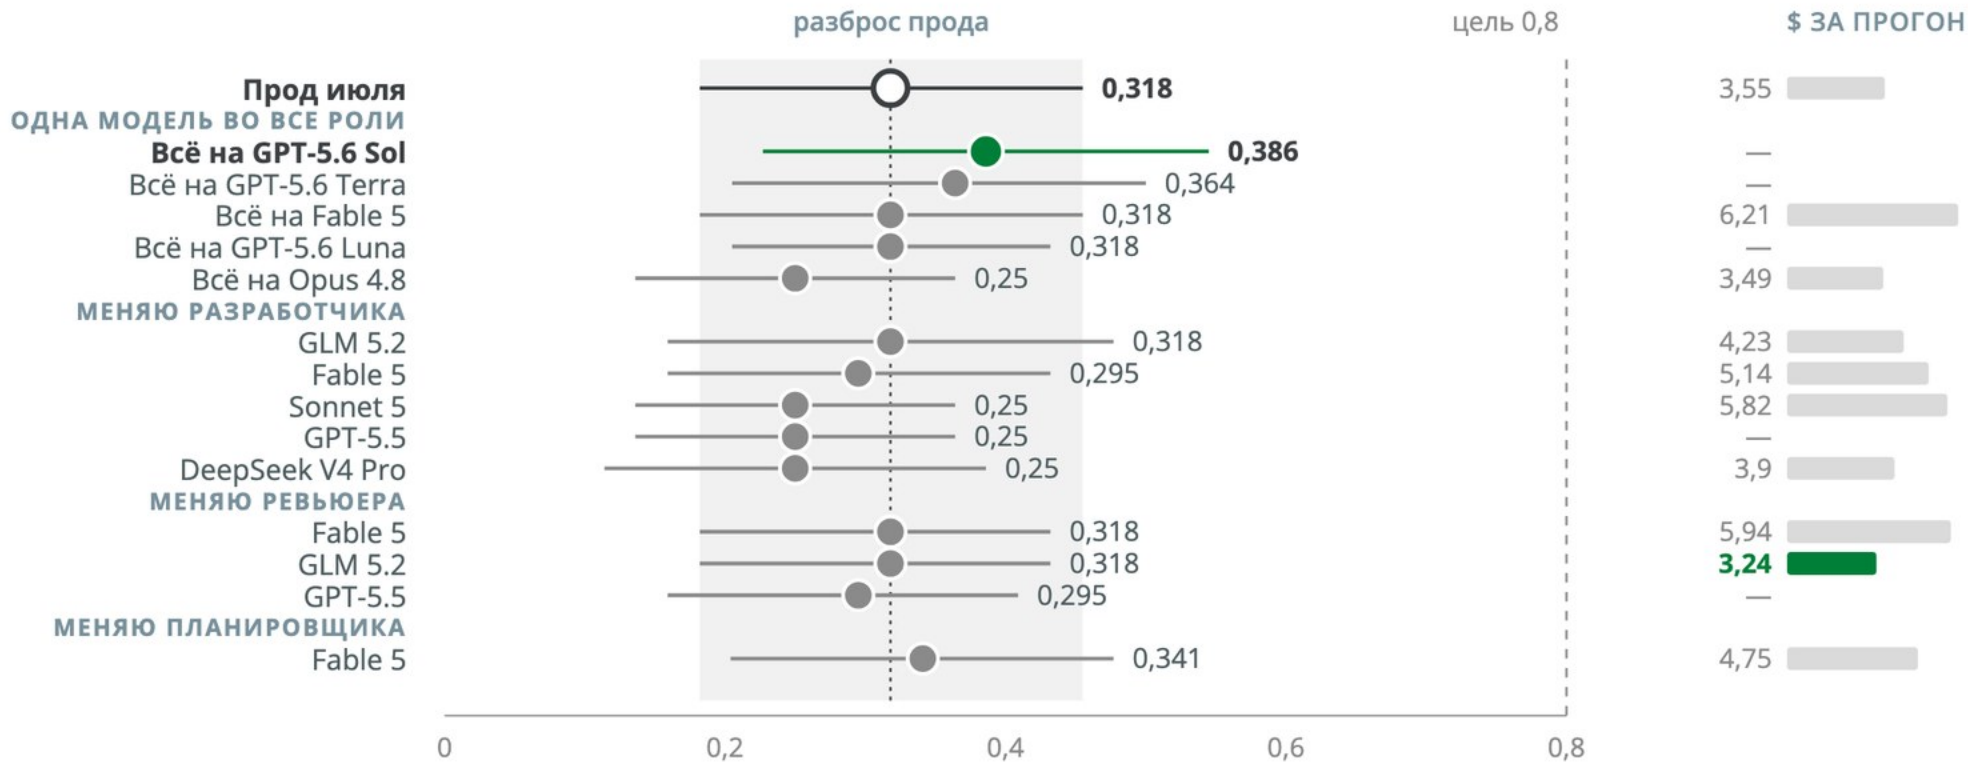
Восемь стеков разной тяжести: Python-бэкенды, React-фронтенды, Node-бэкенд смежного проекта и легаси-веб на собственном фреймворке.

В наборе есть эталонные задачи и **проблемные**, на которых пайплайн уже сбоил. Они ловят регрессии.

У каждой задачи есть готовый ответ: **дифф человека, который уехал в прод**. С ним и сравнивается решение агента.

Один код, 15 составов: разница в пределах шума

доля решённых задач · старый код (флаги выключены), одни и те же 11 задач, июль · в зоне шума 15 из 15

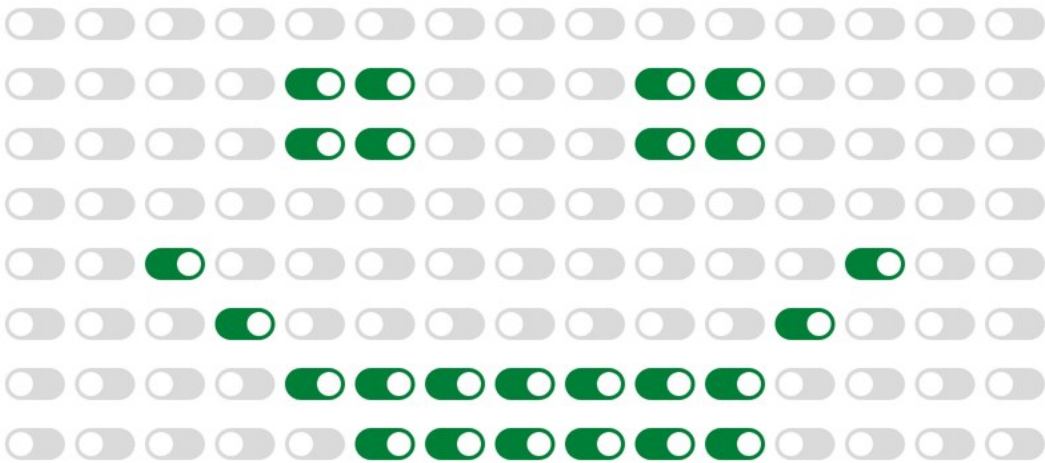


Серая полоса — разброс прода (95% интервал по задачам).
Тот же прод, перезапущенный через неделю, дал на 0,09 больше.
Где не сказано иное: план, код и ревью — Opus 4.8, QA — Haiku. «—»: GPT-5.6 по подписке, цена не записалась.

Каждая фича рождается выключенной

фиче-флаги в коде · включён только тот, что прошёл три сита

120 фиче-флагов: новая фича приезжает в прод выключенной



25 включены: прошли живую проверку

95 выключены

КАК ФЛАГ ВКЛЮЧАЕТСЯ: ТРИ СИТА

1 Синтетика
синтетические репозитории с задачами от лёгкой к сложной, балл стенда из 100

2 Сложная выборка
реальные задачи, где пайплайн сбоил: парный прогон с флагом и без

3 Живая задача
включаю для отдельных пользователей или ночью и по логам смотрю, срабатывает ли флаг

прошёл все три: флаг включён

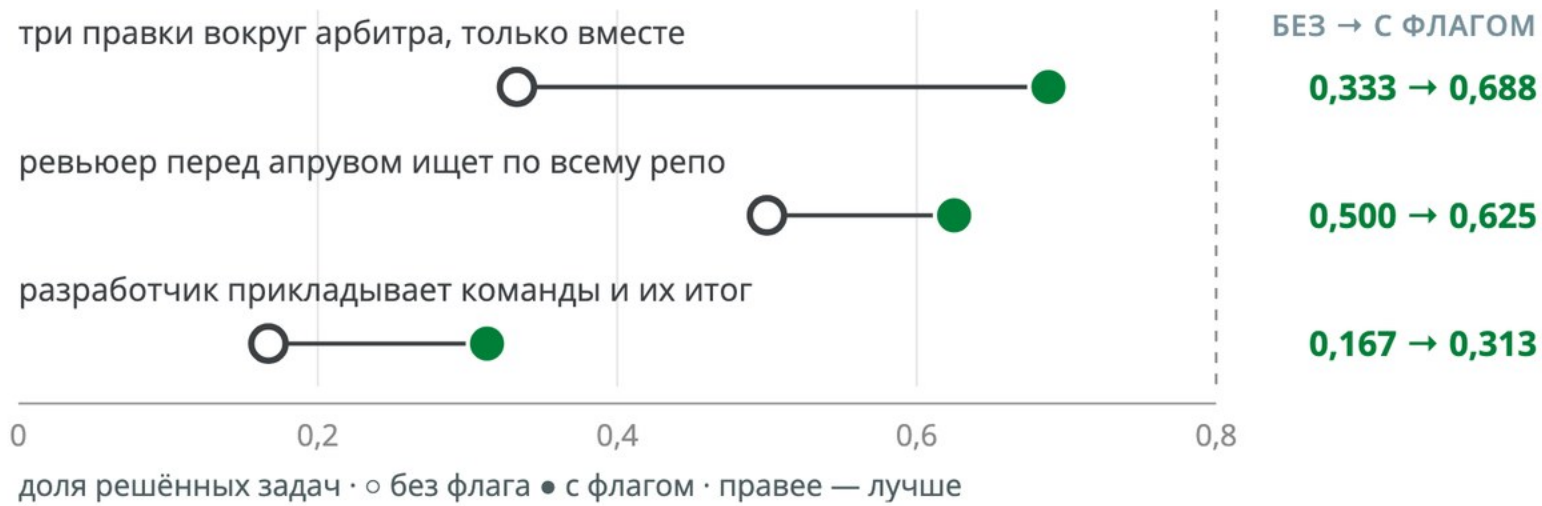
В прод дошли 9 гипотез из 20

доля решённых задач без флага и с флагом · парный прогон на задачах, где пайплайн сбоил · цикл 18–23 июля

храню всё сырым → модель разбирает логи → гипотеза под флагом → парный прогон → отчёт за и против → **решаю я**

20 → 9

гипотез за неделю → в проде



С теми же моделями новый код дал +0,11

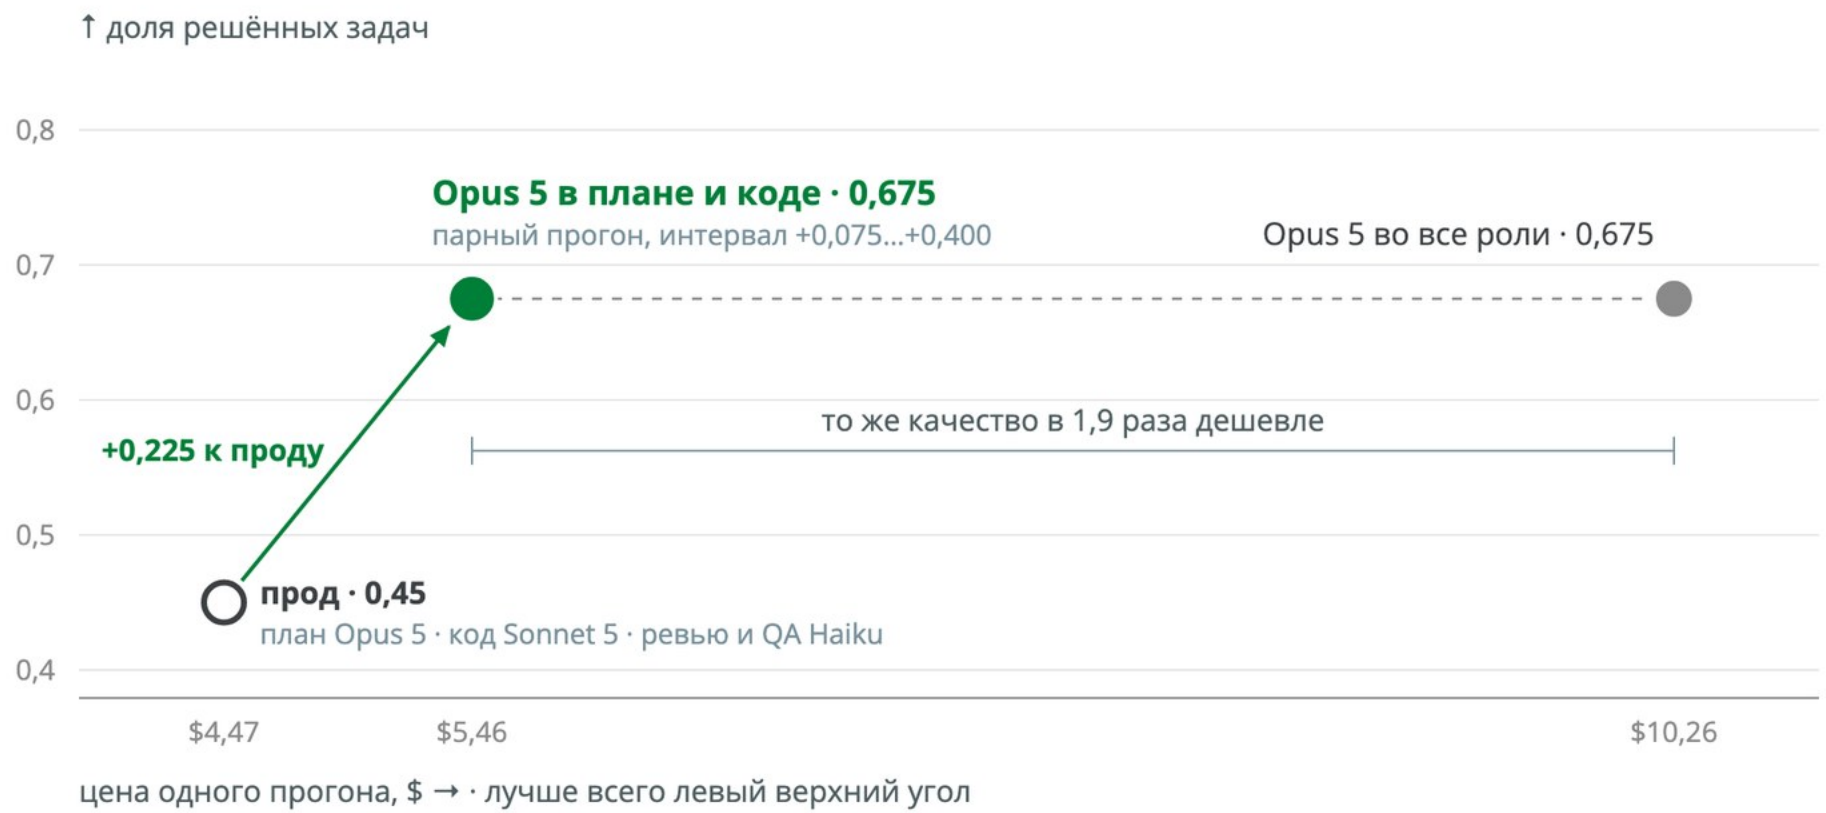
доля решённых задач · одни и те же 11 задач · старый код (июль, флаги выкл.) → новый код (26.07, 76 флагов)



Справа парная разница по задачам и её 95% интервал.

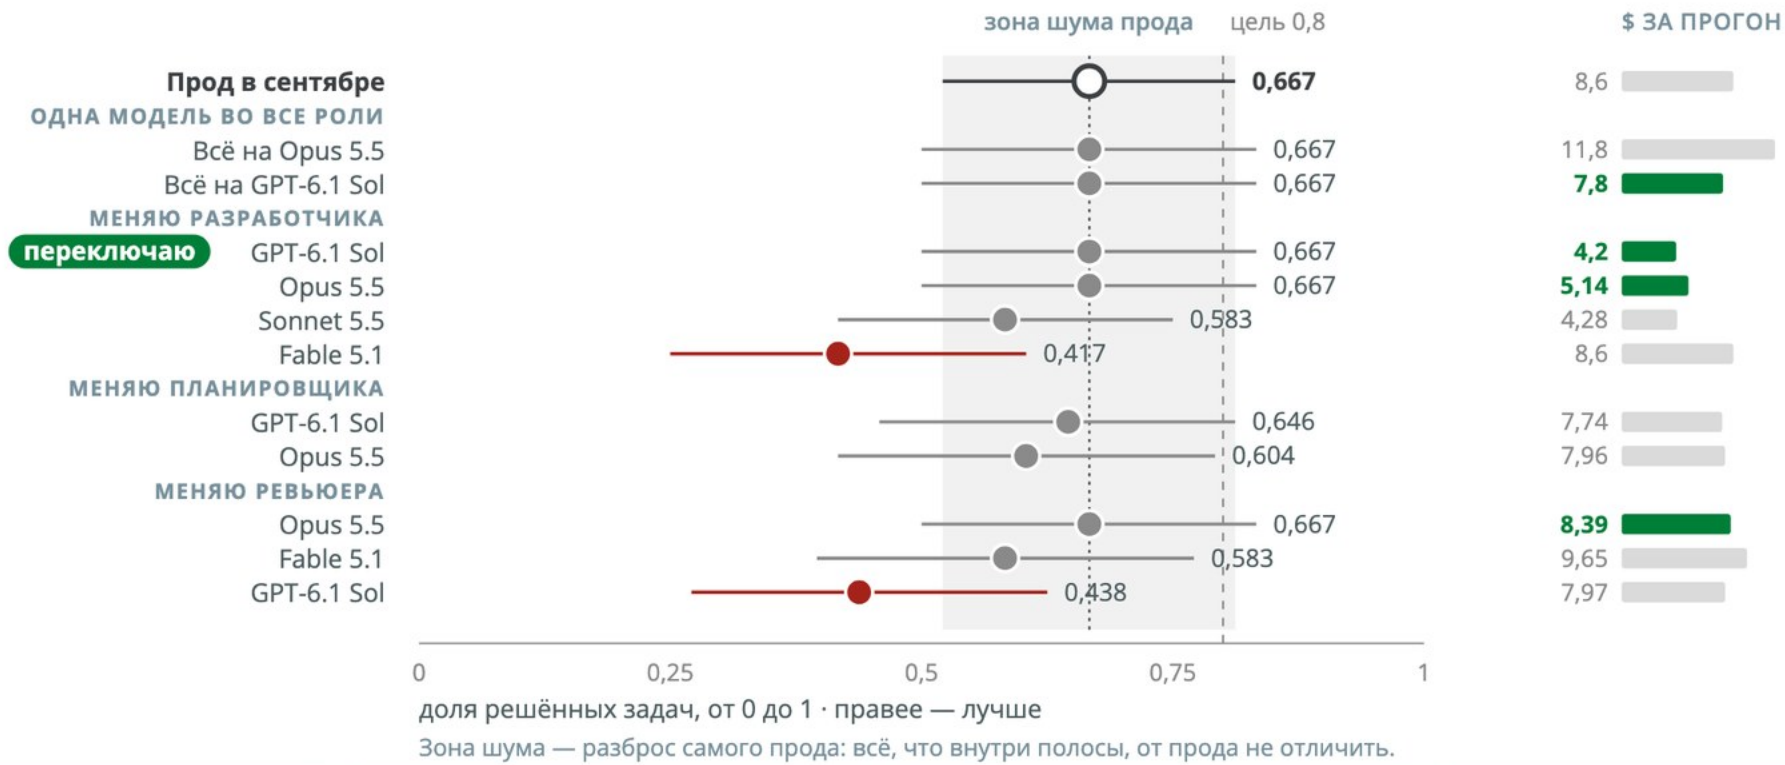
Сильная модель нужна в двух ролях: план и код

`доля решённых задач × цена прогона · новый код, 10 задач волны 7 (26.07)`



Свежие модели: качество одно, беру самую дешёвую

числа со слов автора, не прогон стенда · доля решённых задач · новый код, сентябрь, 12 задач · меняю одну роль, остальное как в проде · в зоне шума 10 из 12



Зона шума — разброс самого прода: всё, что внутри полосы, от прода не отличить.

ПЛАН	КОД	РЕВЬЮ	QA
GPT Astra	**GPT Astra**	**Opus 5**	**GPT-6 Sol**

Память между прогонами уронила качество

изменение доли решённых задач · память между прогонами включена против выключенной



Агент тянул в контекст факты из прошлых прогонов, которые к задаче не относились, и верил им. Код за это время уже уехал вперёд.

Память должна жить в самом проекте, рядом с кодом, и меняться вместе с ним. Такую память **я не включил**: без стенда раскатил бы.

Как он взял не тот API

1

В задаче сказано, что сделать

и ни слова о том, каким API это делать

2

Агент взял похожий

подходящий на вид API из соседнего кода: собралось, тесты зелёные

3

Нужен был другой

внутренний, про него знали разработчики команды, в задаче его не было

4

Ревью завернуло

до прода не дошло

Если в задаче чего-то нет, агент это додумает сам. Чинить пришлось **описание задачи**.

Агент сам выдал себе права

КОММИТ АГЕНТА В РЕПЕ ФРОНТЕНДА

```
chore(env): test commit
  .nvmrc
  mise.toml
  pnpm-workspace.yaml
  .claude/settings.json
```

в последнем файле агент дал себе права на git

ЧТО СЛУЧИЛОСЬ

- Внутри сессии подтянулась новая версия pnpm, ей не хватило Node, и агент стал чинить окружение: поднял Node, создал конфиги, дал себе права
- Правка была не нужна: пайплайн к тому моменту уже поставил зависимости
- За полгода семь фиксов мусора бота в чужих репах, вплоть до всего node_modules/ в MR

КАК ПОНЯЛ

> MR три итерации ходил по кругу: ревьюер просил убрать конфиги, без них падал CI, фиксер возвращал их обратно

Вам так не надо: перед пушем пусть код пайплайна сравнит всю ветку с базовой и откатит настройки агента и окружения. Он работает после сессии агента, и переписать его агент не может

Пустой план значит «все репы»: 12 MR на правку в полстроки

ПЛАН ПОСЛЕ ТАЙМАУТА ПЛАНИРОВЩИКА

```
repo_types: []
```

пустой список код понимал как «все репы»

ЧТО СЛУЧИЛОСЬ

- Задачу на полстроки перезапустили из Slack, а такой перезапуск обходил выбор репы по метке
- Планировщик 30 минут изучал все 12 реп и упал по таймауту. Дальше 12 разработчиков параллельно, часть MR пустые, $24
- После починки тот же перезапуск: 1 репа, 1 MR, $0,6

КАК ПОНЯЛ

> Команда решила, что виновата модель. По логам эта модель в прогоне не участвовала, сломана была оркестрация

Вам так не надо: сразу делайте так, чтобы пустой ответ и таймаут стадии валили прогон, а роутинг был один для всех входов

Бот стал брать всё, что готово к разработке, и за полтора часа взял 42 старые карточки

БОТ В ТРЕКЕРЕ ЗА ПОЛТОРА ЧАСА

42

карточки 2021–2025 годов, у многих спринт давно закрыт

ЧТО СЛУЧИЛОСЬ

- Раньше задачи для бота искали люди и вешали метку. Тут перевернули: бот берёт всё, что готово к разработке, а лишнее люди помечают ai-skip
- Изменение конфига, сделанное для двух проектов, уехало на все, а проверка спринта смотрела только «поле не пустое»
- 34 карточки ушли в анализ с упоминаниями людей, 5 дошли до MR

КАК ПОНЯЛ

> Бот взял и сделал задачу, закрытую ещё в 2025-м. Откатил всё скриптом по истории трекера, а пинги людям уже ушли

Вам так не надо: прежде чем отдать боту всё, что готово к разработке, поставьте фильтр по возрасту и статусу карточек и почистите бэклог в Jira

Свой системный промпт проиграл на дистанции

БЫЛО: СВОЙ ВМЕСТО РОДНОГО

```
system_prompt=opts.system_prompt
```

СТАЛО: РОДНОЙ + СВОЙ APPEND

```
system_prompt={
  "type": "preset",
  "preset": "claude_code",
  "append": CODER_APPEND}
```

ЧТО СЛУЧИЛОСЬ

- Долго выбирал: дописывать мои инструкции поверх системного промпта или переписать его целиком
- Переписал целиком и несколько месяцев так жил. Работало лучше, чем дописывать
- Приходилось переписывать все системные промпты и следить, что меняется в родном

КАК ПОНЯЛ

> Вышли новые версии харнесов, того же Claude Code, и их промпты стали лучше моих. А с атрибутом SDK «добавить к системному промпту» качество выросло

Вам так не надо: по максимуму перекладывайте работу с инструментами на провайдера. Свой промпт сначала будет работать лучше, но обгонять их всё время на длинной дистанции сложно

Что повторяется, я забрал у модели в код

падения планировщика и доля решённых задач · 15 прогонов без правки и 15 с ней · стенд, июль

без правки · падений 3 из 15



с правкой · падений 0 из 15

● упал на ответе в JSON ● дошёл до судьи

доля решённых задач



○ без правки ● с правкой · правее — лучше

ЧТО ЗАМЕТИЛ

- Решать, повторить стадию или остановиться, я сначала отдал модели. Она трижды подряд сказала «повтори» на один и тот же блок, по 50 минут каждый раз
- 24 из 25 падений на стенде были у планировщика: модель пропускала в JSON поле, которое пайплайн уже посчитал сам

ЧТО СДЕЛАЛ

> Каждый повторившийся случай стал правилом в коде: известные ошибки код ловит до модели, после двух одинаковых блоков стоп. Поле убрал из схемы. Модели остались только незнакомые ошибки и то, где надо думать

Вам так не надо: сразу переносите в код всё, что повторяется или известно заранее, а модели оставляйте то, где надо думать

Агент удалил фичу коллеги, потому что так было написано в тикете

ПЛАН АГЕНТА, ПОЛЕ CONTRADICTIONS

```
"Existing precedence tests must
 change to match the requested
 single-version contract"

review: APPROVE
```

противоречие в плане записано, вопроса человеку нет

ЧТО СЛУЧИЛОСЬ

- Тикет просил, чтобы в документации API была та же версия, что отдаёт сервис. Раньше другой разработчик сознательно вывел туда хэш коммита, и агент это убрал
- Противоречие запускало только перепроверку плана другими моделями, человека никто не спросил
- В другой задаче спека владельца на ~8,5 тыс. символов не влезла в лимит на комментарии в 8 000 и выпала целиком

КАК ПОНЯЛ

> Спросил, почему он так сделал. Ответ лежал в его же плане: агент делает ровно то, что увидел

Вам так не надо: сразу превращайте противоречие с существующим кодом в вопрос человеку до разработки и логируйте, что не влезло в контекст

Задачи описаны плохо: что я пробовал

ТРЕБОВАТЬ ОТ ЛЮДЕЙ → ДЕЛАТЬ ЗА НИХ

Шаблон задачи в Jira
люди заполняют, когда заводят задачу руками

Расписывать задачу до файлов и API
человек сам указывает, где менять

Бот сам собирает задачу из треда
уточняет вопросы и заполняет тот же шаблон

Префлайт эпика с метками
нужен контекст · не подходит · можно брать

КОНТЕКСТ О ПРОЕКТЕ

Профайл проекта
раз в неделю бот сканирует репы

Скиллы проекта, из репы и общие
их пишут разработчики

Самообучение скиллов
бот сам предлагает по повторам

Память между прогонами
бот помнит факты из прошлых задач

КОНТЕКСТ О ЗАДАЧЕ

Поиск по карточкам и Swagger
что в компании зовут формой лимитов

Вложения, скриншоты, Figma
скачиваются на старте

Агент сам ходит в трекер и вики
одна сессия с доступом на чтение

Лог того, что не влезло в контекст
после спеки на 8,5 тыс. символов

ПРОВЕРИТЬ ДО РАЗРАБОТКИ

Дешёвая проверка до дорогих стадий
непонятно — вопрос автору в карточке

Перепроверка после правки описания
люди чаще отвечают правкой описания

Консенсус моделей по плану
несколько моделей проверяют план

Противоречие с кодом — вопрос человеку
до того, как агент начал писать код

Задачи описаны плохо: работает только это

ТРЕБОВАТЬ ОТ ЛЮДЕЙ → ДЕЛАТЬ ЗА НИХ

Шаблон задачи в Jira
люди заполняют, когда заводят задачу руками

отказался
~~**Расписывать задачу до файлов и API**~~
тогда зачем агент

Бот сам собирает задачу из треда
уточняет вопросы и заполняет тот же шаблон

Префлайт эпика с метками
нужен контекст · не подходит · можно брать

КОНТЕКСТ О ПРОЕКТЕ

Профайл проекта
раз в неделю бот сканирует репы

Скиллы проекта, из репы и общие
их пишут разработчики

проверяю
Самообучение скиллов
бот сам предлагает по повторам

не взлетело
~~**Память между прогонами**~~
−12% на стенде

КОНТЕКСТ О ЗАДАЧЕ

Поиск по карточкам и Swagger
что в компании зовут формой лимитов

Вложения, скриншоты, Figma
скачиваются на старте

проверяю
Агент сам ходит в трекер и вики
одна сессия с доступом на чтение

проверяю
Лог того, что не влезло в контекст
после спеки на 8,5 тыс. символов

ПРОВЕРИТЬ ДО РАЗРАБОТКИ

Дешёвая проверка до дорогих стадий
непонятно — вопрос автору в карточке

Перепроверка после правки описания
люди чаще отвечают правкой описания

выключил
~~**Консенсус моделей по плану**~~
человека так никто и не спросил

Противоречие с кодом — вопрос человеку
до того, как агент начал писать код

Что пока не получилось

0,68

лучший результат на сложной выборке при цели 0,8



Человека агент пока не заменяет

КОММЕНТАРИЙ РАЗРАБОТЧИКА В MR

> «Я лучше сам сделаю»

Часть фич я делал зря

ПРОСИЛИ **превью на своей машине**

Правило: предлагаешь фичу, расскажи, кто ей будет пользоваться

Что я проверяю сейчас: одна сессия агента против 23 ролей

слепая дуэль на 16 реальных задачах · одна сессия против MR, который открыл бот · замер 25–26.09

ПОВОД

> Люди писали, что самому сделать быстрее

ЭКСПЕРИМЕНТ · СБОКУ ОТ ПРОДА

Одна сессия агента
со всеми инструментами: сама читает задачу и код, планирует и пишет

→

Гейт без модели
линт и тесты; что упало, уходит обратно в ту же сессию

→

Ревьюер
отдельная сессия со свежим контекстом, до двух раундов правок

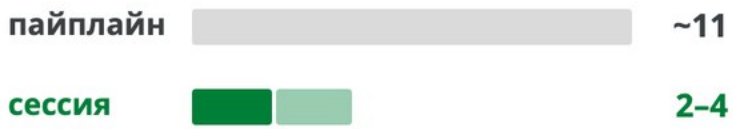
9 побед 2 ничьи 5 поражений



одна клетка — одна задача

Судьи — четыре модели разных семейств. Каждая видит задачу и два диффа в случайном порядке и не знает, где чей

ВЫЗОВОВ МОДЕЛИ НА ЗАДАЧУ



в 4 раза дешевле, почти в 5 раз быстрее
против средней по проду за два месяца

ОГОВОРКА

16 задач, доверительного интервала нет, в проде этого пока нет. Несколько недель тестирую в shadow-режиме: рядом с продом на живых задачах, MR не открывает

Если бы начинал сейчас

СДЕЛАЛ БЫ СРАЗУ

- ✓ Стенд и одно число до любых изменений, дальше мерить постоянно: всё быстро меняется `18% · 10-й день`
- ✓ Одна сессия агента, гейт без модели и ревьюер. Новая роль только после замера `9 из 16`
- ✓ Что повторяется или известно заранее, решает код `3/15 → 0/15`
- ✓ Системный промпт и работу с инструментами оставить провайдеру, своё дописывать сверху
- ✓ Из моделей одного качества брать самую дешёвую `вдвое дешевле`
- ✓ Шаблон задачи, контекст бот добирает сам, спорит с кодом — вопрос человеку
- ✓ Бот берёт всё готовое к разработке, людям метка ai-skip. Но сначала чистый бэклог `42 карточки`

НЕ ДЕЛАЛ БЫ

- ✗ Суммаризатор между стадиями `хуже` и память в самом боте `-12%`
- ✗ Фичу, у которой нет пользователя `превью на своей машине`
- ✗ Просто запрещать агенту: он найдёт обход

А КАК ЭТО СДЕЛАТЬ У ВАС

Codey забрать нельзя, но своё собирается из готового агента

ЧТО ЕСТЬ У МЕНЯ

Codey — внутренний сервис EXANTE

живёт на нашей инфраструктуре, лайт-версии, которую можно поставить у себя, пока нет

ЧТО МОЖНО СДЕЛАТЬ У СЕБЯ

Взять агента из коробки

Claude Code, Codex или opencode: SDK у них уже есть

Пройти пять шагов

Сначала замер руками, платформа потом

1 **Агент из коробки**

Claude Code, Codex или opencode по API-ключу или по корпоративной подписке

2 **Пара настоящих задач у себя локально**

из своего бэклога целиком: доводит ли агент задачу до MR

3 **Потом десять задач руками**

без автоматизации: запускаете сами и смотрите, как он работает

4 **Посчитайте, сколько из десяти MR вы бы приняли**

это ваша точка отсчёта, как мои 18% в марте: с ней сравниваете всё дальше

Пять обязательных кусков скелета

1 **Триггер**

метка в трекере; задачи можно забирать поллингом по расписанию, вебхук не обязателен

2 **Изоляция**

свой worktree или контейнер и своя ветка на каждый прогон

3 **Агент: сначала план, потом код**

одна сессия: читает код и задачу со вложениями, пишет план, по нему делает; план уходит в MR

4 **Гейт без модели и ревьюер**

линт и тесты по изменённым файлам теми же командами, что в CI; что упало, уходит агенту на фикс; потом ревьюер на модели другого семейства

5 **MR**

в описании план, что по нему сделано и какие были оговорки

Как понять, что задача описана понятно

1 **В описании есть что-то кроме ссылки и заголовка**
«см. тред» и «как обсуждали» без пересказа не считаются

2 **Понятно, что именно поменять**
вопрос или обсуждение без просьбы что-то сделать — для агента не задача

3 **Всё нужное лежит в самой карточке**
чужой тред и закрытую ссылку агент не увидит; скриншоты и Figma годятся

4 **Пять разработчиков сделали бы одно и то же**
если вышло бы пять разных решений, задача размыта

5 **Решение уже принято**
выбор за продакта или дизайнера, доступы и оценку на глаз агент не сделает

ПРОВЕРКА

Дешёвой моделью до дорогих стадий. По умолчанию пропускать: нет критериев приёмки или тестов — не повод отказать. Отказ — комментарием, чего не хватает

ПОСТАНОВЩИКАМ

Шаблон или скилл, который соберёт задачу сам: результат, где это, «готово, когда»

О чём договориться до включения

1 **Кто смотрит MR бота**

в каждом проекте один человек, меняется раз в спринт, чтобы не надоедало

2 **Как выключить одним движением**

всё новое за фича-флагами; кто и что нажимает, решите до первого запуска

3 **Кто отвечает за описания задач**

у формата должен быть хозяин: продакт или аналитик со своим шаблоном или скиллом

4 **Как подключается новый проект**

одна схема для всех: какая метка за что, когда бот смотрит MR, сколько ждать

Что мерить с первого дня

1 **Сохраняйте всё в сыром виде**

ответы моделей, артефакты и каждую команду, которую запускал агент; задним числом это не собрать

2 **Набор задач разной сложности**

лёгкие и сложные из своего бэклога, состав от замера к замеру не меняется

3 **Умная модель не спасёт плохое описание**

если результат плохой, сначала перечитайте задачу, потом меняйте модель

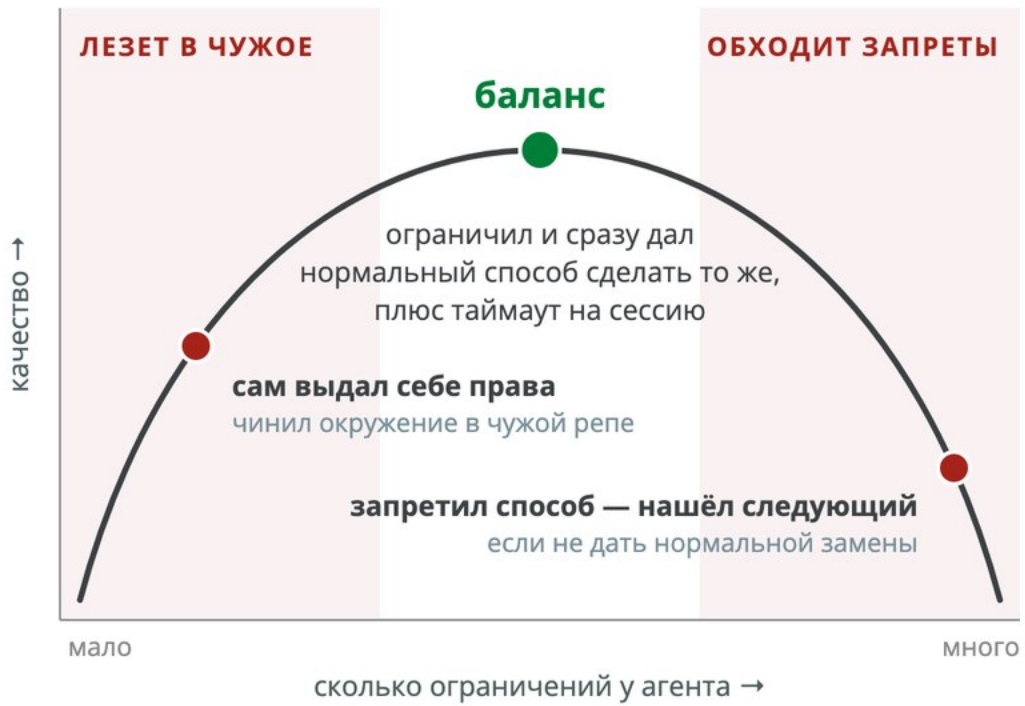
Пять шагов, чтобы собрать это у себя

1. Замер руками: сколько из десяти MR вы бы приняли
2. Скелет из пяти кусков: одна сессия агента, гейт и ревьюер
3. Договориться: кто смотрит MR, как выключить, кто пишет задачи
4. С первого дня хранить всё в сыром виде и держать набор задач
5. Дальше по одному изменению через парный прогон, модели на слово не верьте

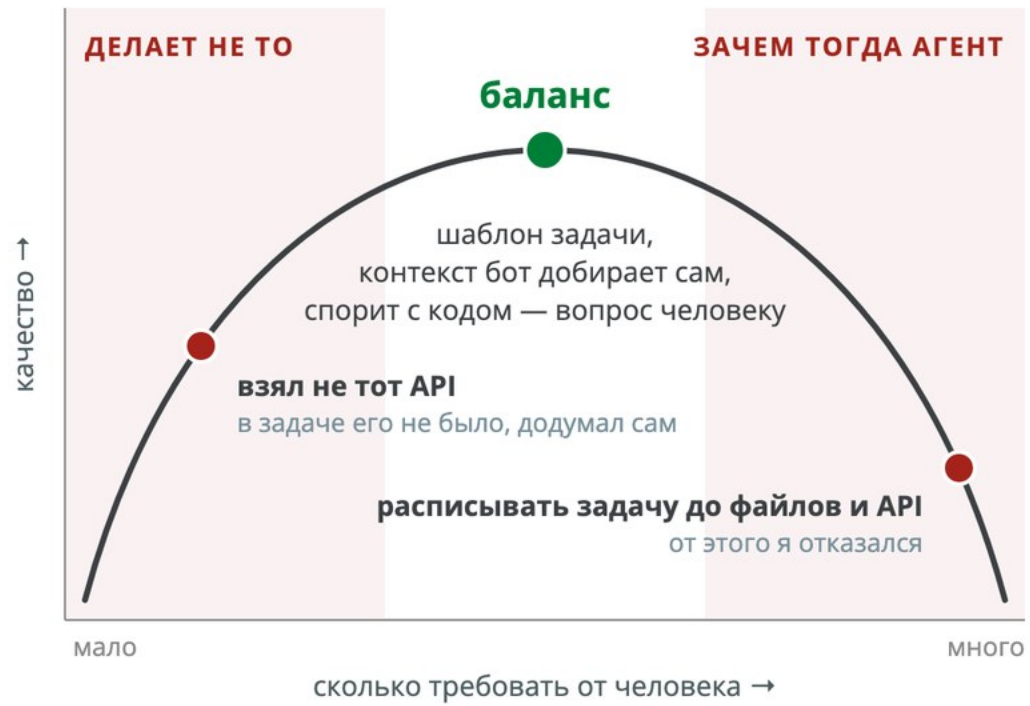
Два баланса: сколько ограничивать агента и сколько требовать от человека

схема, не замер · выше — лучше · истории из блока «Грабли»

1 · АГЕНТ: СКОЛЬКО ОГРАНИЧИВАТЬ



2 · ЧЕЛОВЕК: СКОЛЬКО ТРЕБОВАТЬ



EXANTE
Next Generation Investment Company

Спасибо

Codey · EXANTE · Podlodka AI Crew #4

Вопросы — сейчас голосом, потом — в чате Crew или мне напрямую

Telegram: @miky_muz · muzm@exante.eu



LINKEDIN

linkedin.com/in/mikymuz