podlodka

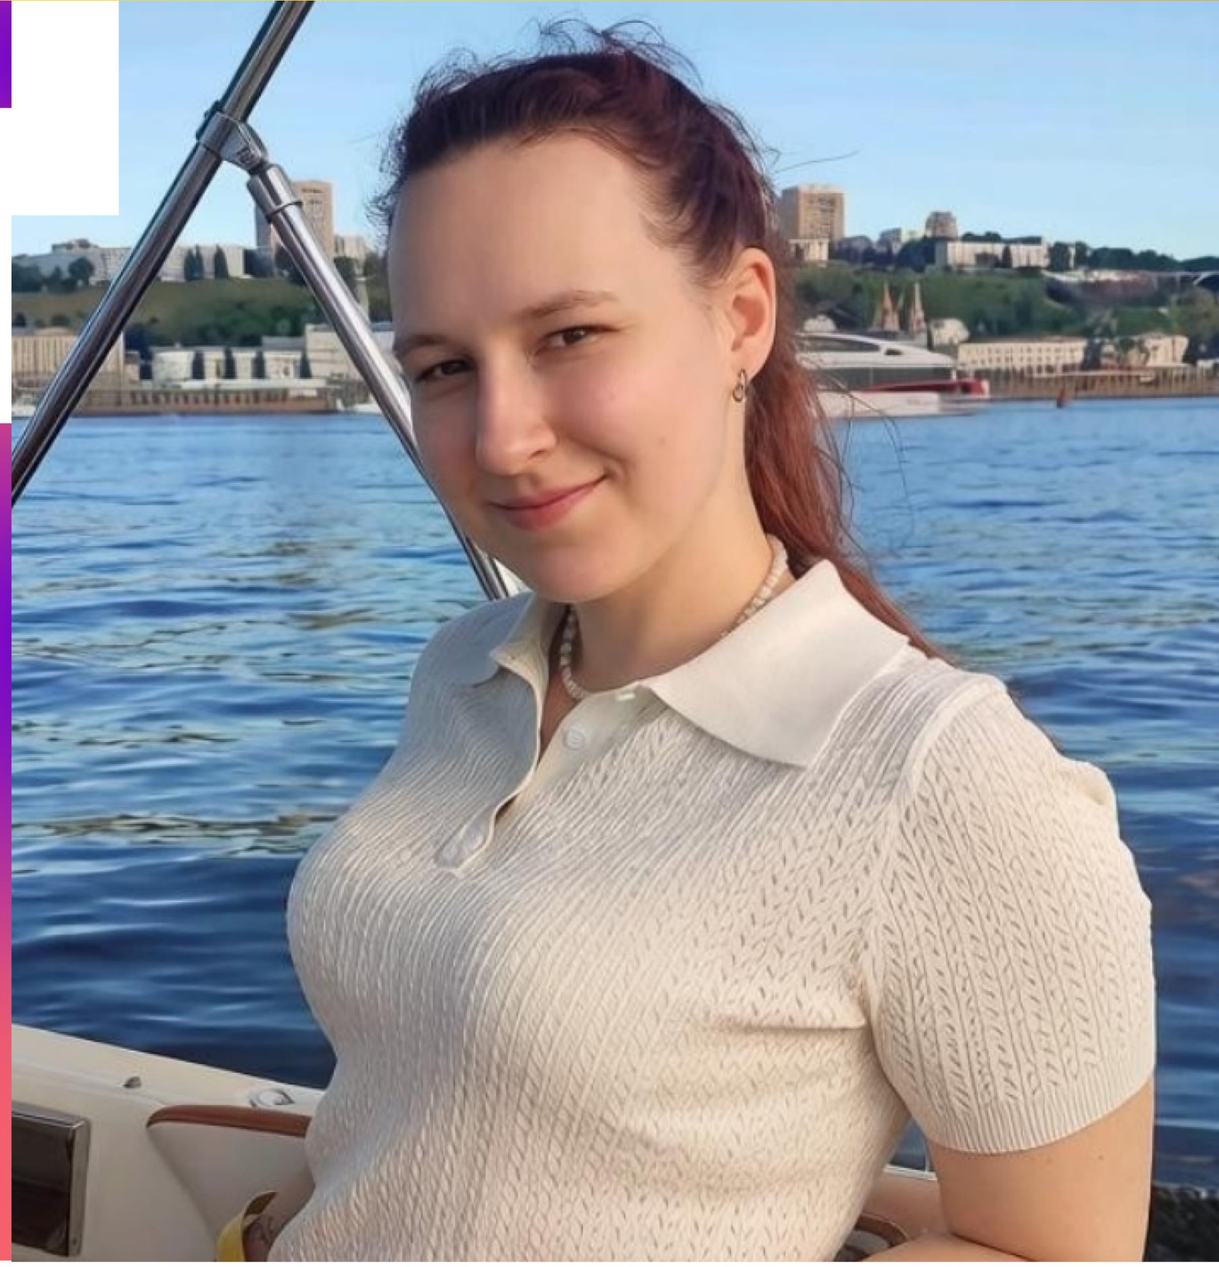
AI Crew
12 - 16 октября

Мультиагентные системы

Надежда Волкова
Ведущий инженер, Т-Банк

Демо-сессия

ИИ-коллега команды разработки



RWB Selectel

Т БАНК

ИИ-агент команды SDLC

Надежда Волкова

Надежда Волкова

Т-Банк, ведущий инженер



- Core Tech
- 4 года в Т-Банке, 9 лет в IT
- Делаем ИИ-инструменты для SDLC

О чем поговорим

1. Что такое ИИ-агент?
2. Длинные сессии агента
3. Работа с кодом и изоляция
4. Безопасность
5. Чат
6. Метрики



Что такое ИИ-агент?

LLM

LLM – Large Language Model

Общаемся с LLM через API
API – **stateless**

Latency – **секунды**

```
{
 "model": "gpt-4o-mini",
 "messages": [
  { "role": "system",
    "content": "You are a helpful assistant..." },
  { "role": "user",
    "content": "Read the file config.json" } ],

 "tools": [ {
   "type": "function",
   "function": {
     "name": "read_file",
     "description": "Read the contents of a file",
     "parameters": {
       "type": "object",
       "properties": {
         "path": { "type": "string",
           "description": "Path to the file" }
       },
       "required": ["path"]
     }
...
```

LLM


```
{
 "created": 1791451422,
 "model": "gpt-4o-mini",
 "choices": [ {
  "message": {
   "role": "assistant",

   "content": "Sure, I will read it! \n",
   "reasoning_content": "The user wants me to read
a file called config.json.\n",

   "tool_calls": [ {
     "id": "call_860afd4f68fd4672a7698109",
     "index": 0,
     "type": "function",
     "function": { "name": "read_file",
      "arguments": "{\"path\":\"config.json\"}" }
    } ] },

  "finish_reason": "tool_calls"
...
```


Модель отвечает текстом

В ответе могут быть «мысли» – **ризонинг**

Запросы на вызовы тулов – **тул-коллы**

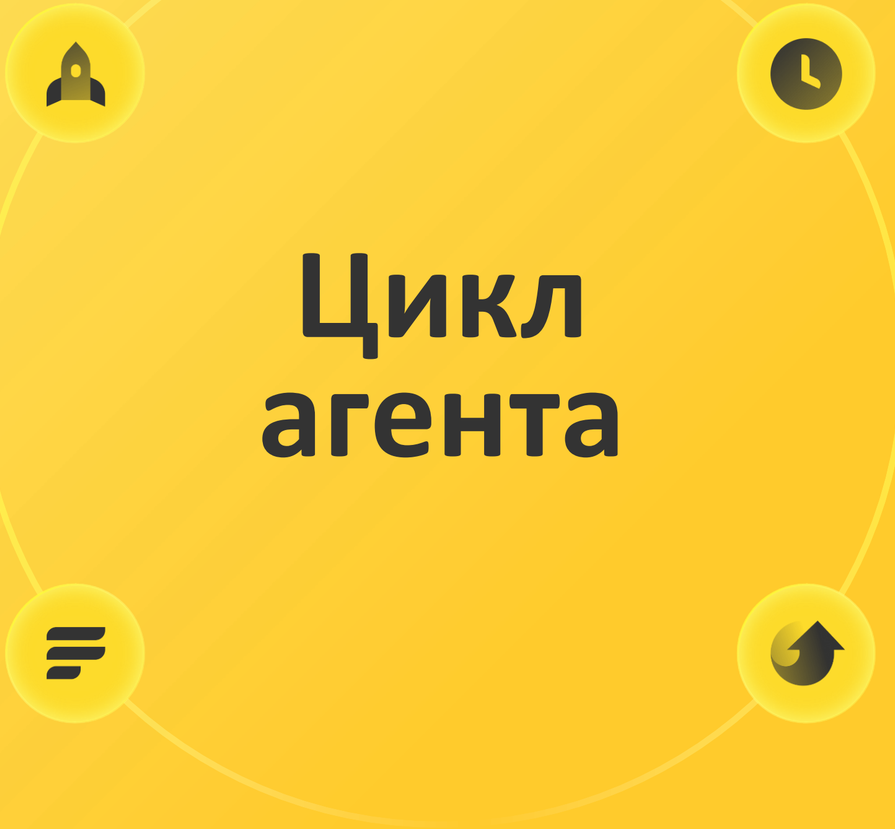
Цикл агента

Запрос в модель

Модель отвечает тул-коллами

Вызываем тул-коллы

Добавляем в историю



Поведение ИИ-агента

Скиллы

Заготовленные сценарии работы, знания, скрипты

Планирование

Агент составляет план работы и следует ему

Саммаризация

Сжатие истории сообщений, когда она достигает порога

Сабагенты

Агент запускает свою копию с собственным контекстом

Что мы хотим?



ИИ-помощник

Общаться через корпоративный чат

Закрывать рутинные задачи команды

Автоматизация

Рутинные этапы работы над задачей:

DoD, DoR, код, тесты, ревью, и т.д.

В перспективе – ИИ-конвейер SDLC

Безопасность

Внутренние модели

RBAC

Изолированная среда

Масштаб

Потенциальная аудитория –

10к человек из IT-подразделений

Конвейер на локальном CLI

Claude Code, Codex, OpenCode…

Чат

CLI или UI

Анализ

Агент изучает задачу,
задает вопросы

Кодинг

Агент пишет код,
запускает тесты

Ревью

Агент исправляет замечания

Merge Request

Profit



Давайте масштабировать!

Хотя бы на 500 человек

Локально?

- Дорого
- Долго
- Ненадежно
- Хочется чтобы «само»



Облако?

- По контейнеру на каждого агента
- Изоляция!
- Дорого
- Как сделать чат?



Бекенд?

- Дешево!
- Длинные сессии?
- Куда клонировать код?
- Безопасность?



Как мы делали Тихона?

25’Q3	25’Q4	26’Q1	26’Q2
Бот ответов по докам	Переход на langchain4j Интеграции с gitlab, jira, wiki	Свое ядро агента	Автономный кодовый агент



3000

WAU – уникальные пользователи за неделю

4.1

Удовлетворенность по CSAT

90%

Кода Тихона пишет ИИ

Сегодня



Nadezhda Volkova 11:10 AM

объясни что такое делегированные токены



Tihon Бот 11:11 AM

Delegated tokens (делегированные токены) — это механизм обмена токенов в Spirit IAM, который позволяет сервису получить токен **от имени другого субъекта** (пользователя или другого сервиса), без знания его учёток.

Суть в паре слов:

- **Token exchange** — обмен текущего access-токена на другой (с другими правами/аудиторией), через эндпоинт вроде OAuth2 token exchange (RFC 8693).
- **Delegated** — итоговый токен оформляется как "действующий от имени" того, кто делегировал права (субъект / actor), а не от самого приложения.

Применение: сервис-A аутентифицируется от имени пользователя в сервисе-B, который доверяет Spirit IAM, не получая логин/пароль. Удобно для B2B/межсервисного контекста и проверки прав пользователя.

Вчера

Mikhail B. 9:03 AM

> Nadezhda Volkova
> что ж, видимо, текущего фикса недостаточно

Попробуете убрать?



Nadezhda Volkova 9:07 AM

@Tihon заведи новую задачу под это



Tihon Бот 9:10 AM

Задача создана.

✅ **Задача создана:** PCAI-710

Параметры:

- **Тип:** Initiative
- **Приоритет:** Minor
- **Компонент:** Tihon
- **Team:** PSD CoreTech AI Tools
- **Initiative classification:** Развитие текущей функциональности
- **Assignee:** Nadezhda Volkova
- **Статус:** New

Описание: проблема с утечкой процессной информации в финальный отчёт sandbox при вызове из CI (несмотря на уборку технического префикса в MR !742), с критериями приёмки.

Сегодня



Tihon Бот 2:55 PM

Задача API-4729 перешла в статус Review

Обновление ручки закрытия



Tihon Бот 3:05 PM

📌 **Definition of Done для API-4729**

✅ Основные требования задачи реализованы.

⚠️ **Главные риски:**

- расхождение с ТЗ в правиле `number = question_index + 1` (и тест это закрепляет);
- не реализована валидация `question_type_code` (ТЗ требует 500 на неправильный тип);
- не прокидываются `authorizationx-workspace-id` из входящего запроса;
- зависимость от ещё не готовой задачи команды Polls API-4748.

🚫 Вердикт: **НЕ ГОТОВО**

Части системы

Чат в мессенджере

Там, где общается команда

Бекенд-агент

Инструменты до внутренних ресурсов

CLI-агент

Для кодинга



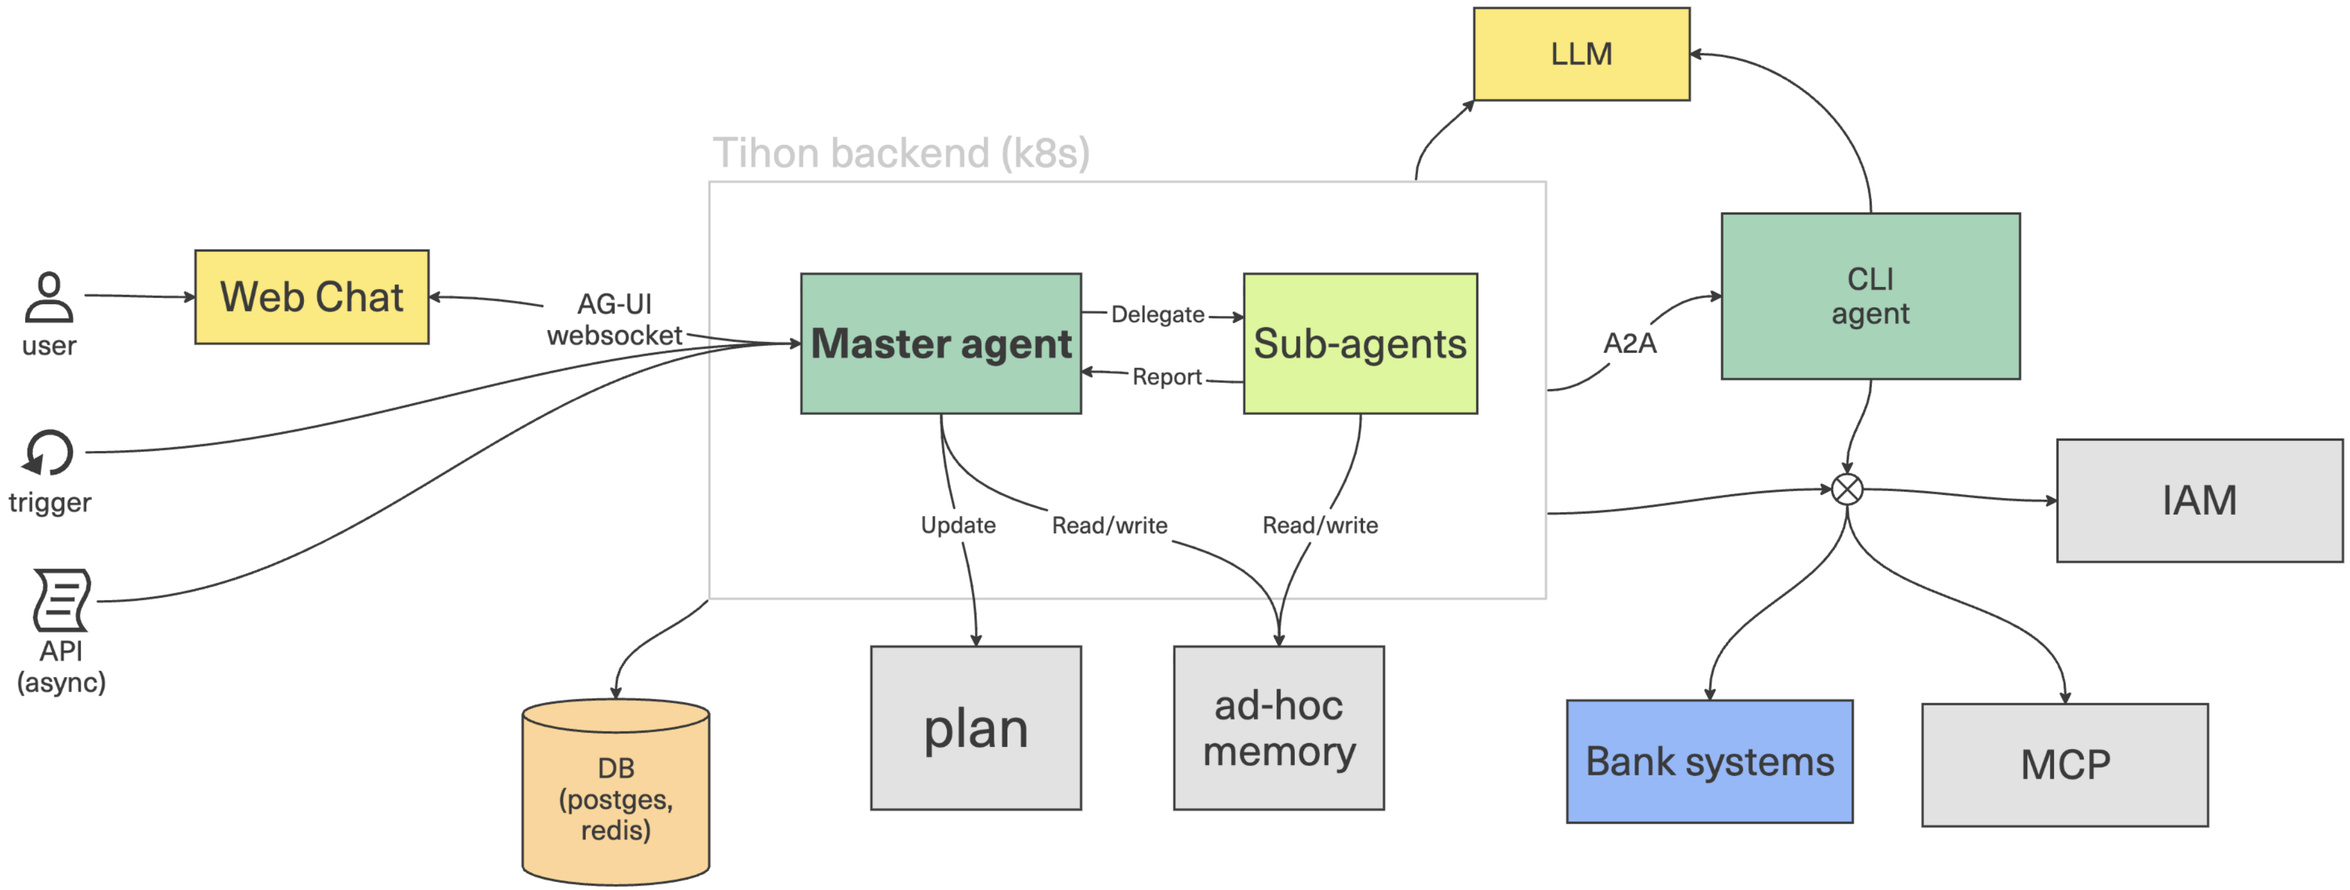
Админка

Настройки пользователей

Веб-чат

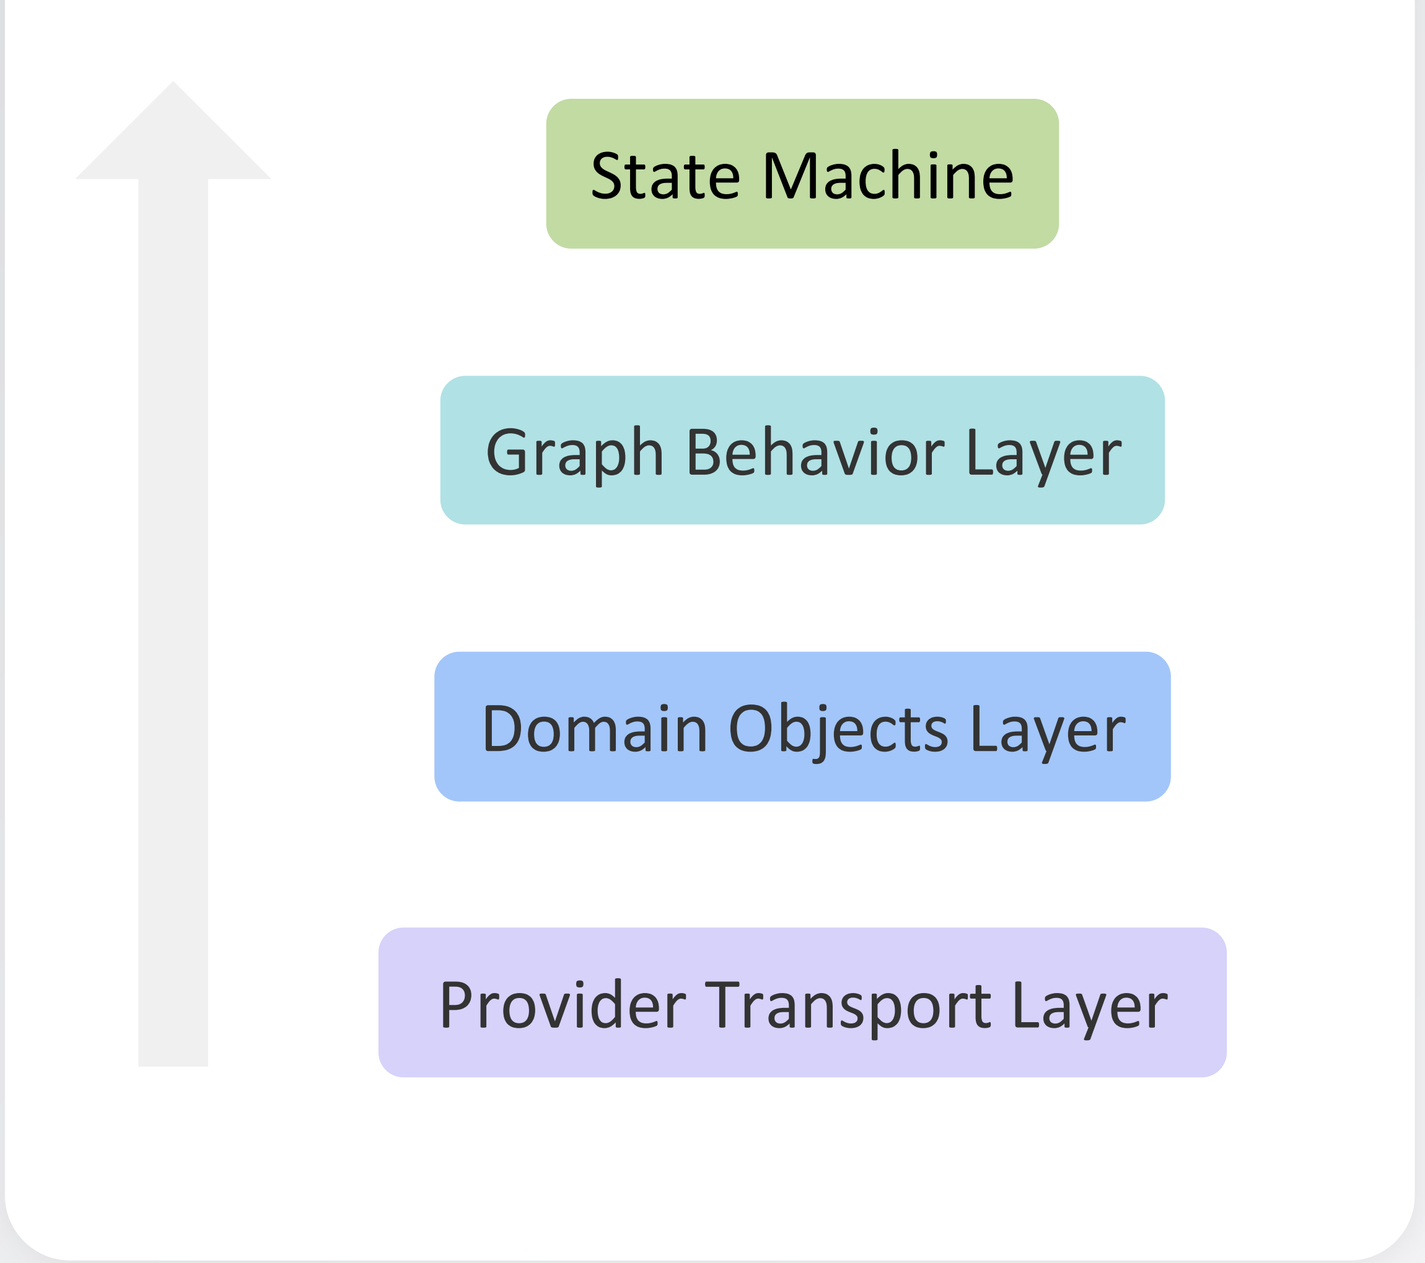
В браузере и Chrome плагине

Компоненты системы



Архитектура агента

- Одно ядро – Java + Spring
- Бекенд-агент – сервис в k8s
- CLI-агент – изолированная среда



Модель данных

```
public sealed interface LLMMessage
        permits LLMMessage.User,
                LLMMessage.Assistant,
                LLMMessage.ToolCall {

    record User(String content)

    record Assistant(String content, String reasoning)

    record ToolCall(ToolCallRequest request,
                    String response)

    record ToolCallRequest(String id, String name,
                           ObjectNode arguments)
}
```

Граф



Кастомный граф-движок



Каждый узел – одно действие



Легко добавлять
новое поведение

```
public Graph<AgentContext, AgentResponse> build() {
  return new GraphBuilder()

    .edge(GraphBuilder.startNode(), llmCallNode)

    .edge(llmCallNode,
      toolExecutionNode, AgentEdges.ifToolCall())

    .edge(toolExecutionNode,
      llmCallNode, AgentEdges.ifNextCycle())

    .edge(llmCallNode, GraphBuilder.endNode())

    .build();
}
```

Длинные сессии

Сессия переживает редеплой



Длинные сессии

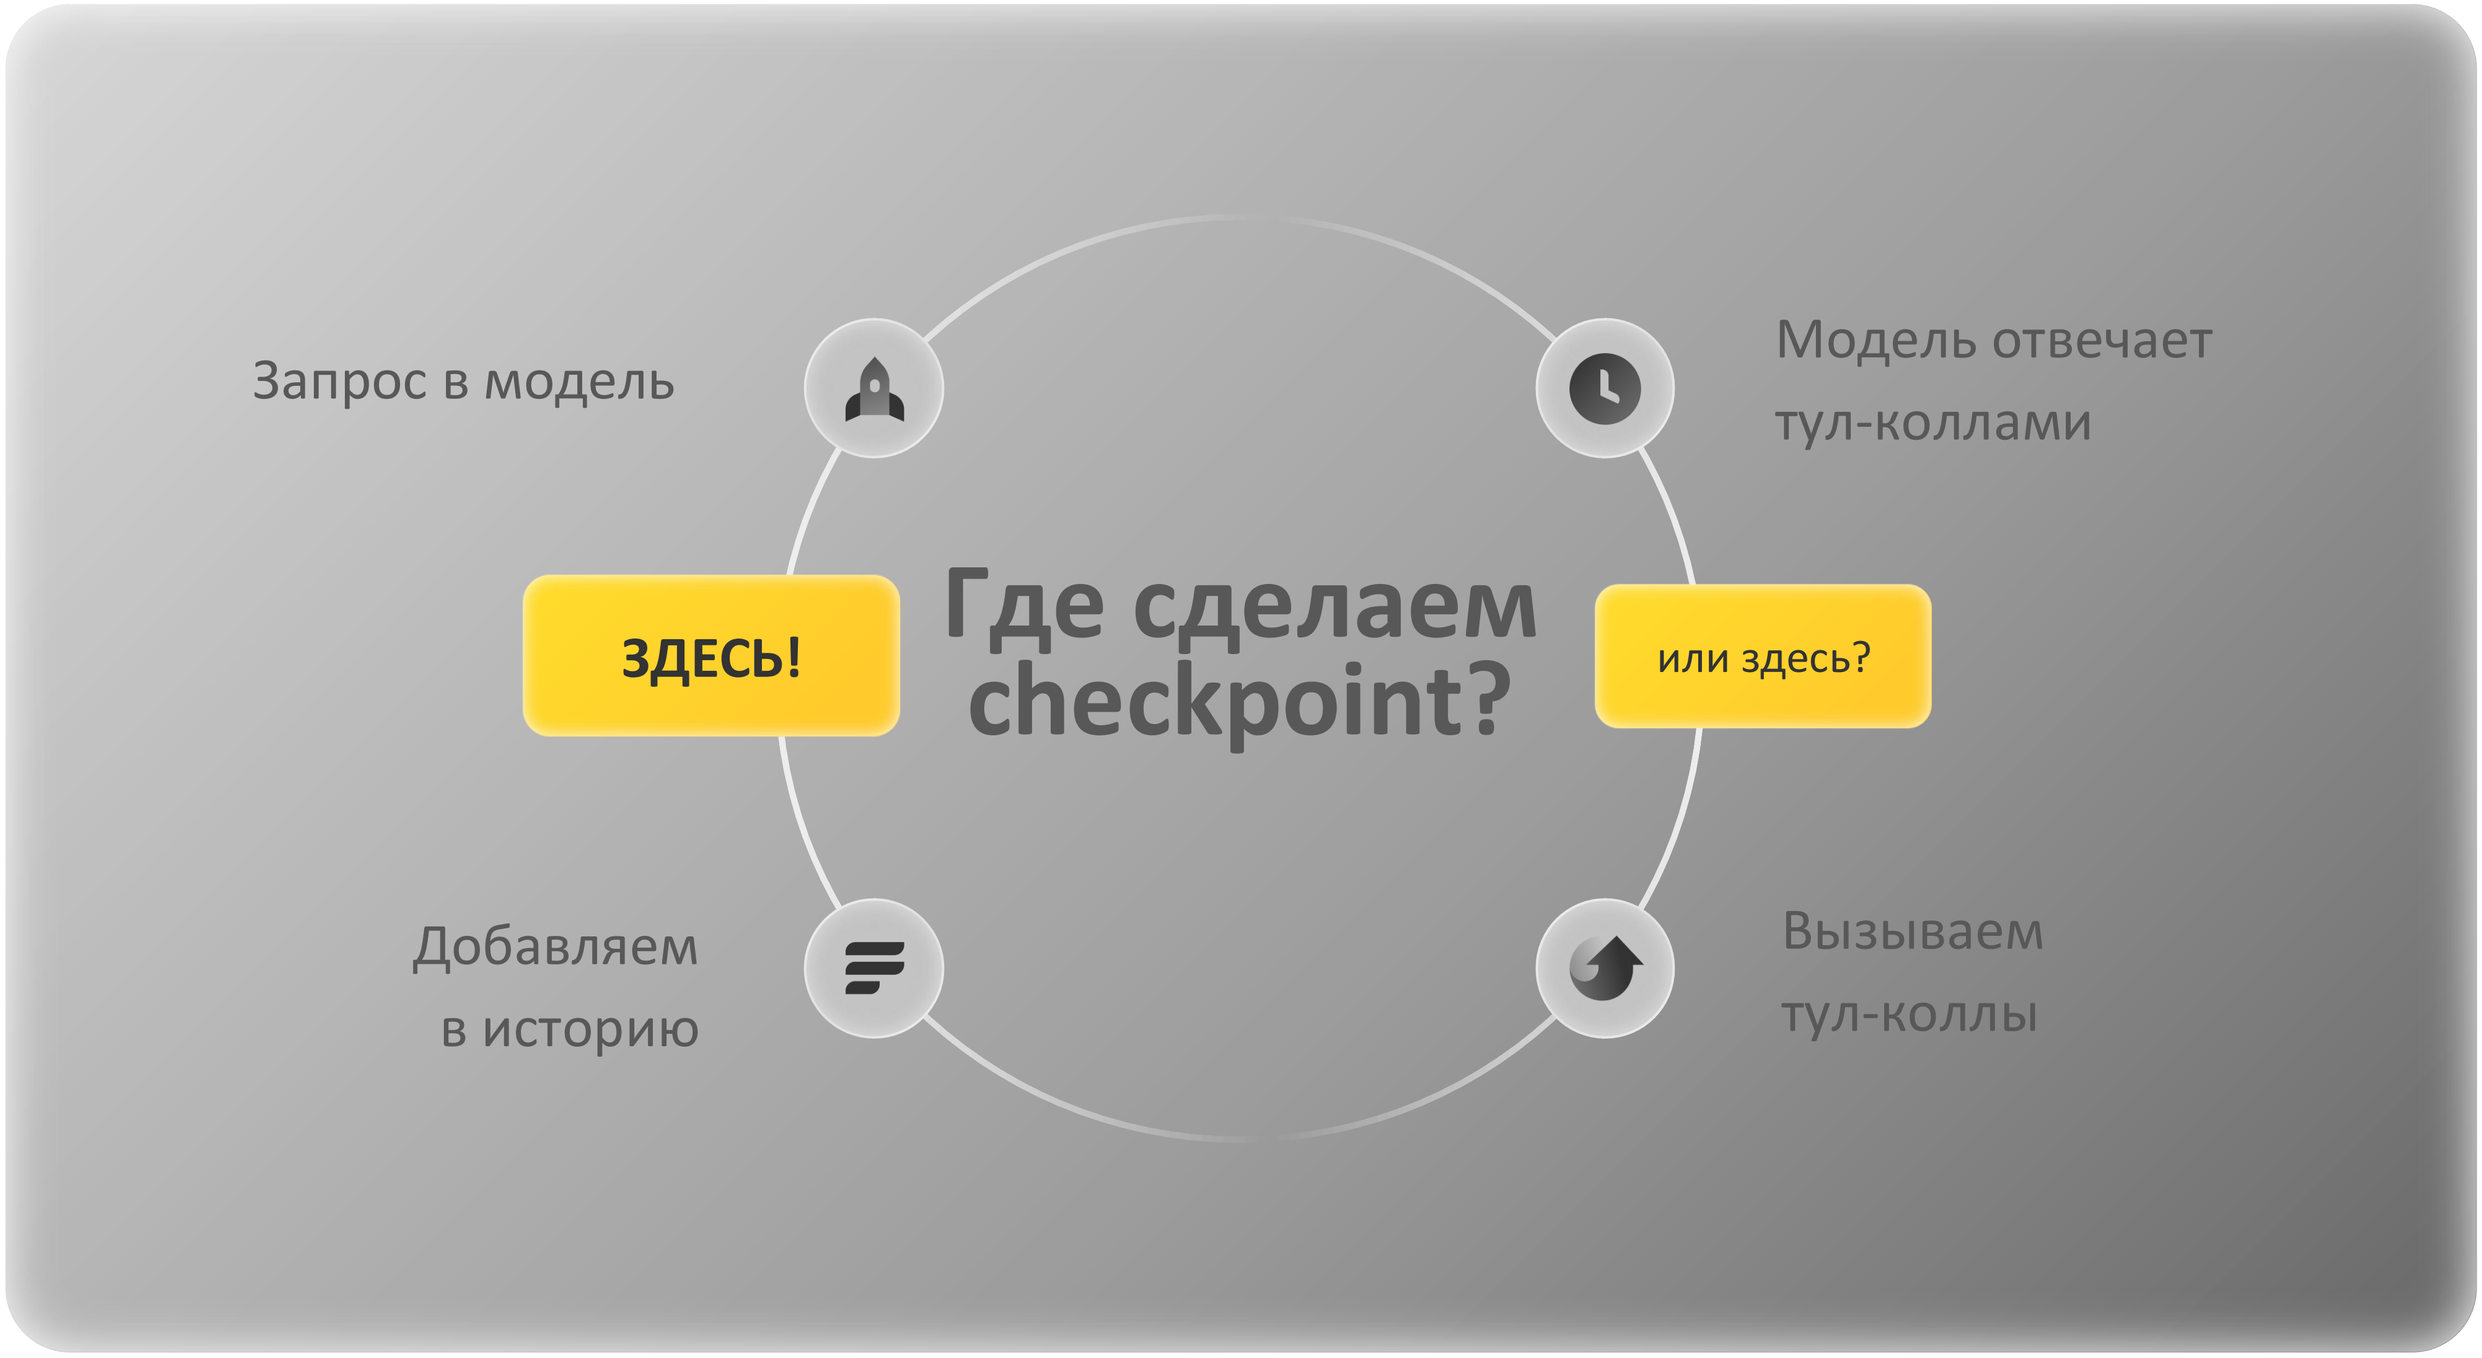
Проблема

- Сессия агента может занимать **часы**
- Бекенд иногда уходит в **редеплой** / рестарт
- Нельзя долго держать в **graceful shutdown**

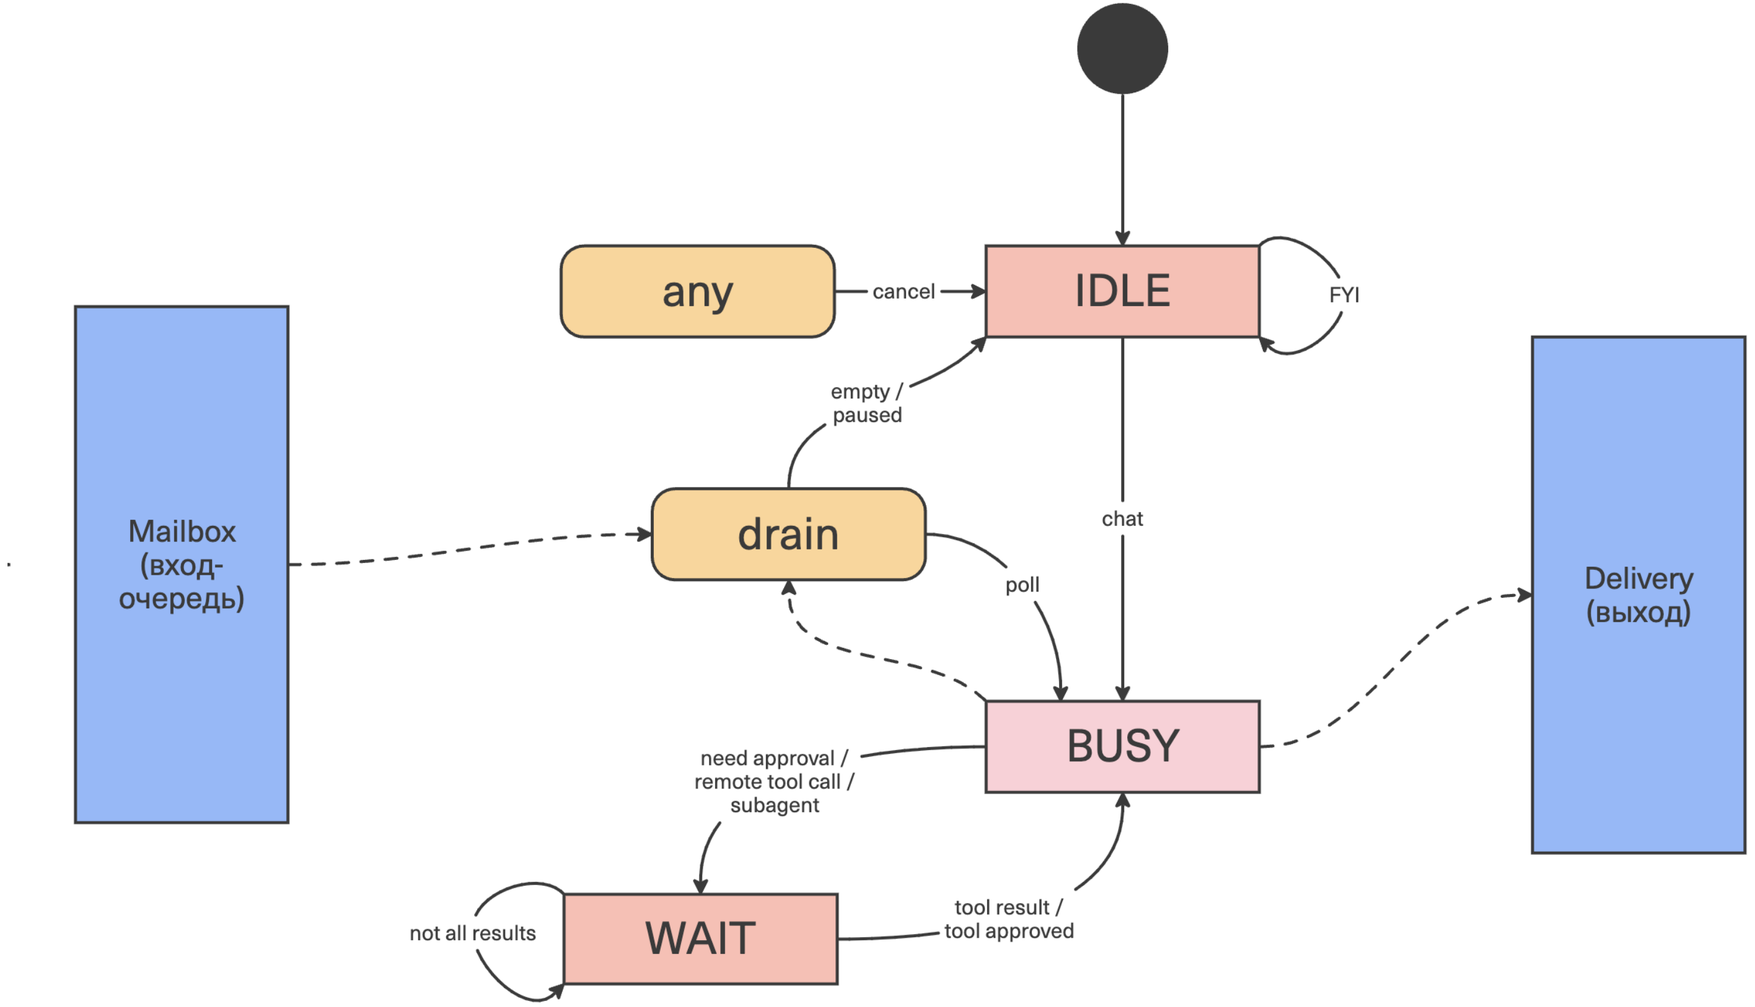
Решение

Нужна асинхронность

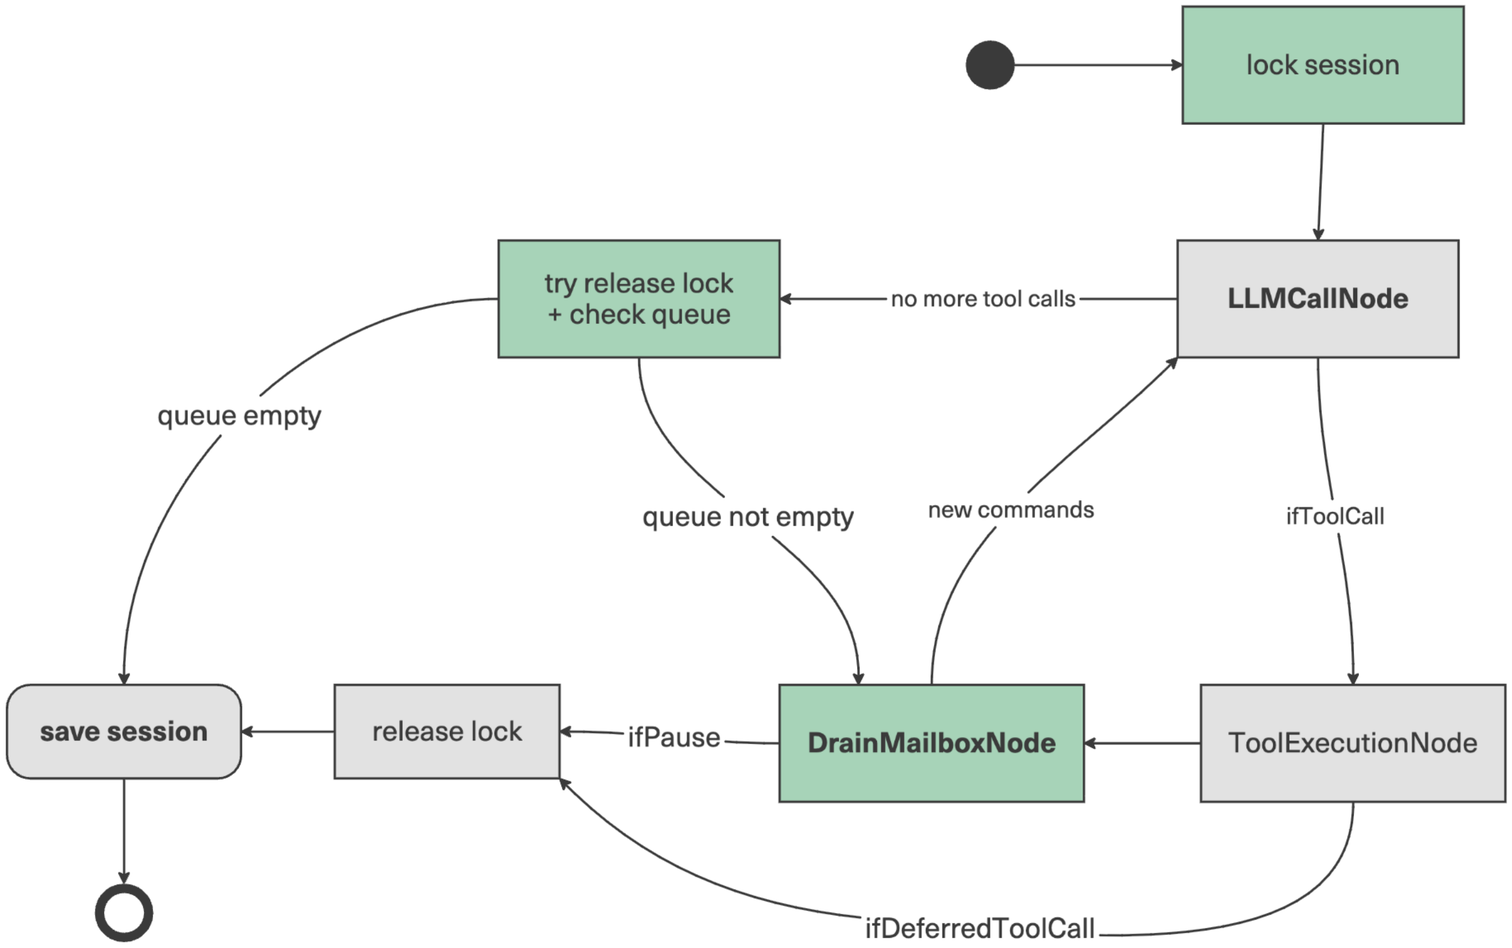
- Нужно сделать ИИ-агента **неблокирующим**
- Нужно **сохранять** состояние в безопасных точках
- И **продолжать** на новом контейнере
- И **не терять данные**


Запрос в модель
Модель отвечает тул-коллами
ЗДЕСЬ!
Где сделаем checkpoint?
или здесь?
Добавляем в историю
Вызываем тул-коллы

ИИ-Агент как state machine



Чекпоинты


lock session
LLMCallNode
no more tool calls
try release lock
+ check queue
queue empty
queue not empty
new commands
ifToolCall
save session
release lock
ifPause
DrainMailboxNode
ToolExecutionNode
ifDeferredToolCall

AgentClient

```
public interface AgentClient {

    void chat(String sessionId, String message);

    void fyi(String sessionId, String message);

    void toolResult(String sessionId,
                    String toolCallId, String result);

    void cancel(String sessionId);

    void pause(String sessionId, Duration deadline);

    void resume(String sessionId);

    Status status(String sessionId);
    enum Status { IDLE, BUSY, WAIT }
}
```

Работа с кодом и изоляция

Агент тестирует

- У агента есть инструменты, чтобы пересобрать и перезапустить себя
- Используем это для тестирования
- CLI-агент тестирует backend по API
- Тестирует UI через Chrome MCP
- Также есть mcp для дебага

Status: **ready** — code implemented, full `./gradlew check` green (tests + Checkstyle + PMD + SpotBugs + ErrorProne), `bootJar` rebuilt.

Important: the currently-running process is the **old** jar, so any ```diff block I emit right now would be rendered by the old code (plain code block). I need to restart first so the new renderer is live, then respond with a ```diff block. Triggering the restart now — I'll send the diff code block in the resumed session:

Tihon Cli Agent - interactive mode - v0.96.2

Restarted — the new build is live. Here's the result: the ```diff code block below is now rendered by the shared diff renderer (same styling as the `replace` tool preview — colored borders, full-width bands, context lines plain):

```
// A ```diff block now renders like a replace-tool diff
        if (language != null && language.equalsIgnoreCase("diff")) {
        if ("diff".equalsIgnoreCase(language)) {
            return renderDiff(trimmedCode);
        }
```

If you see exactly that, the feature works end-to-end. Status recap: implementation + tests done, `./gradlew check` fully green, jar rebuilt and restarted.

If anything looks off (e.g. it still renders as a plain yellow code block, or the bands don't span full width), tell me what you see and I'll fix it.

---

tihon-cli-3 >

Кодовые тулы

- read, write, replace
- grep, glob
- shell

```
public class ReadFileTool extends
        AbstractFsTool<ReadFileTool.Params> {

    record Params(
        @Param("Path to the file to read")
        String path) {}

    @Override
    public ToolDefinition definition() {
      return ToolDefinition.forName("read")
          .description("Read content from a file")
          .schema(Schema.build(Params.class))
          .build();
    }

    @Override
    protected String executeInternal(Params params) {
      return Files.readString(
          resolveAndValidatePath(params.path()));
    }
```

Изоляция работы с кодом

Проблема

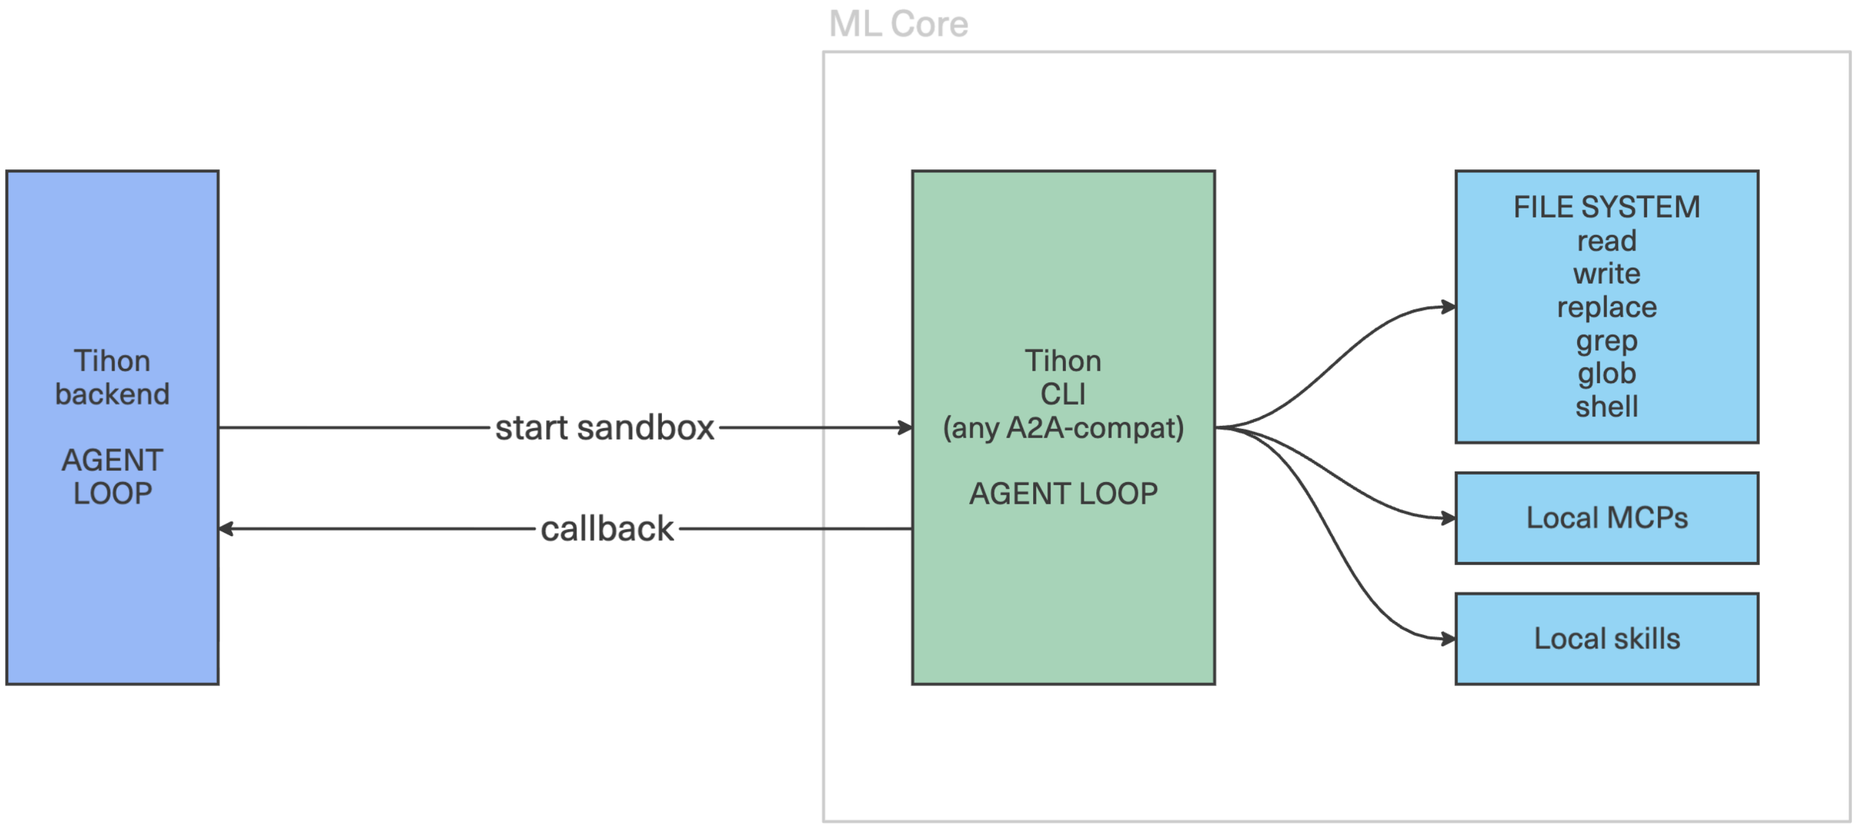
- Нужно куда-то **клонировать** код
- А на **бекенд контейнер** – нельзя
- Агент должен **бесшовно** работать с этим кодом

Решение

sandbox

- Инфраструктура для запуска **контейнеров**
- Заворачиваем CLI-агента в **Dockerfile**
- Даем возможность бекенду вызывать sandbox

Как бекенд вызывает sandbox





Nikita Starkov 1:34 PM

> Nikita Starkov
> Да, сейчас пока это невозможно. Если вы "перекатываете" задачку по одним и тем же статусам — нужно за...

@Tihon мы можем добавить этот момент в документацию о подписках Jira?



Tihon Бот 1:36 PM

Да, мы можем добавить этот момент в документацию. Наиболее логичное место — раздел «🔔 Отслеживание задач (Jira-подписки)» в docs/docs/features/jira.md, где уже описан блок «Важно: Работа подписок». Сейчас там описан механизм паузы подписки, но кейс «повторный переход в тот же статус» явно не выделен.

Предлагаю добавить туда пункт примерно так:

> 3. **Повторный переход в тот же статус**
>   Если задача уже была в статусе, на который настроена подписка, и после возврата снова перешла в этот же статус — новый триггер **не сработает**, пока не закрыт существующий тред.

Также можно добавить короткую заметку в раздел «📭 Подписки Jira» на странице ui-admin/jira-tracker.md.

Хочешь, чтобы я внёс эту правку в репозиторий (подготовлю изменения и создам MR через sandbox)?



Tihon Бот 2:08 PM

Pipeline успешно завершён. Готово!

🎸 Готово! Sandbox-агент завершил работу, изменения внесены, pipeline зелёный.

✅ **MR:** Draft: docs: clarify repeated transition to same status in Jira subscriptions !741

Что сделано:

- `docs/docs/features/jira.md` — в блоке «⚠️ Важно: Работа подписок» добавлен пункт 3 «Повторный переход в тот же статус»: при возврате в уже отслеживаемый статус триггер не сработает, пока не закрыт существующий тред.
- `docs/docs/ui-admin/jira-tracker.md` — в разделе «📬 Подписки Jira» добавлена заметка `:::note` про повторный переход в тот же статус.

Статус:

- CI pipeline `#129063723` — ✅ **success** (lint, build-site, build-gradle, unit-test, component-test прошли).

⚠️ MR создан как **Draft**. Нужно снять с draft и назначить ревьюера (правило quality → @Nadezhda Volkova). Хочешь, чтобы я перевёл MR в ready и/или добавил ревьюеров?

Что еще нужно?

Клонируем репозиторий

Детерминировано клонируем репозиторий и ветку

Устанавливаем runtime

Готовые скрипты для установки нужных runtime

Мониторинг

Состояния sandbox

Таймаут неактивности – 1 час

Spec Driven Development

Скиллы для разработки агентом

→ github.com/obra/superpowers

Цифры

За неделю 21 сен – 29 сен

- **331 MP**
  Создано через Тихона
- **81%**
  Влито в master



Безопасность


Здравствуйте, я специалист по безопасности. Я украл ваш токен.
VULN
VULN
VULN
VULN
VULN
VULN
VULN
VULN
9 задач VULN, лето

Безопасность

Проблема

- ~~ИБ пришли по нашу душу~~
- Использовать **сервис-аккаунт** с широким доступом – **небезопасно**
- Просить ключ у каждого – **неудобно**

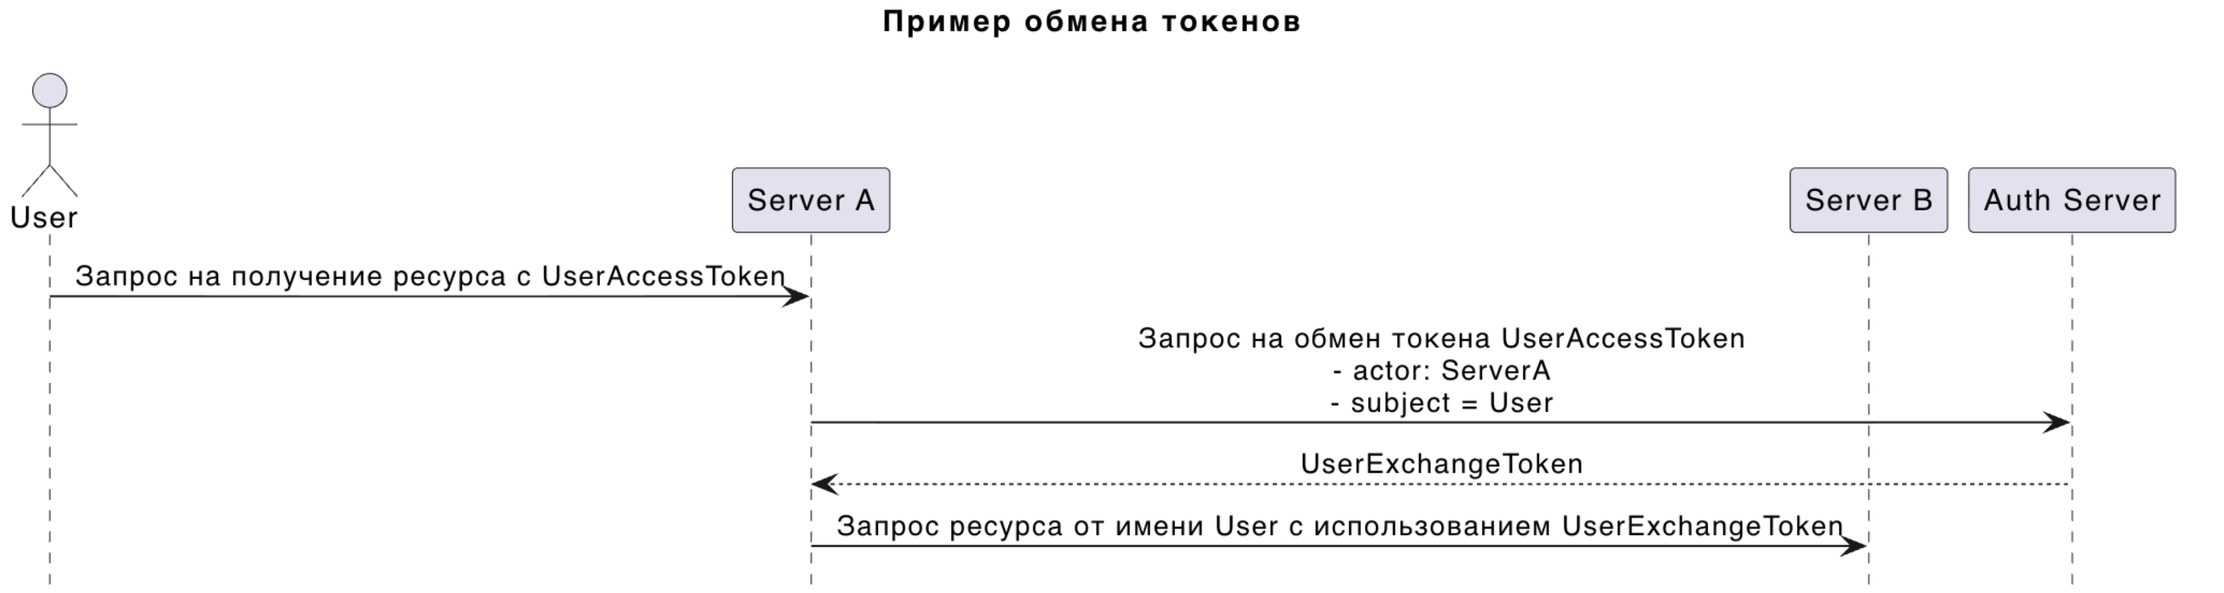
Решение

OAuth 2.0 Token exchange

- Получаем **имя пользователя**
- **Запрашиваем** его токен в конкретную систему
- Используем **только этот токен**

Делегированная авторизация

RFC 8693: OAuth 2.0 Token Exchange.



Делегация в коде



Токены храним в Caffeine



Токен ограничен в правах

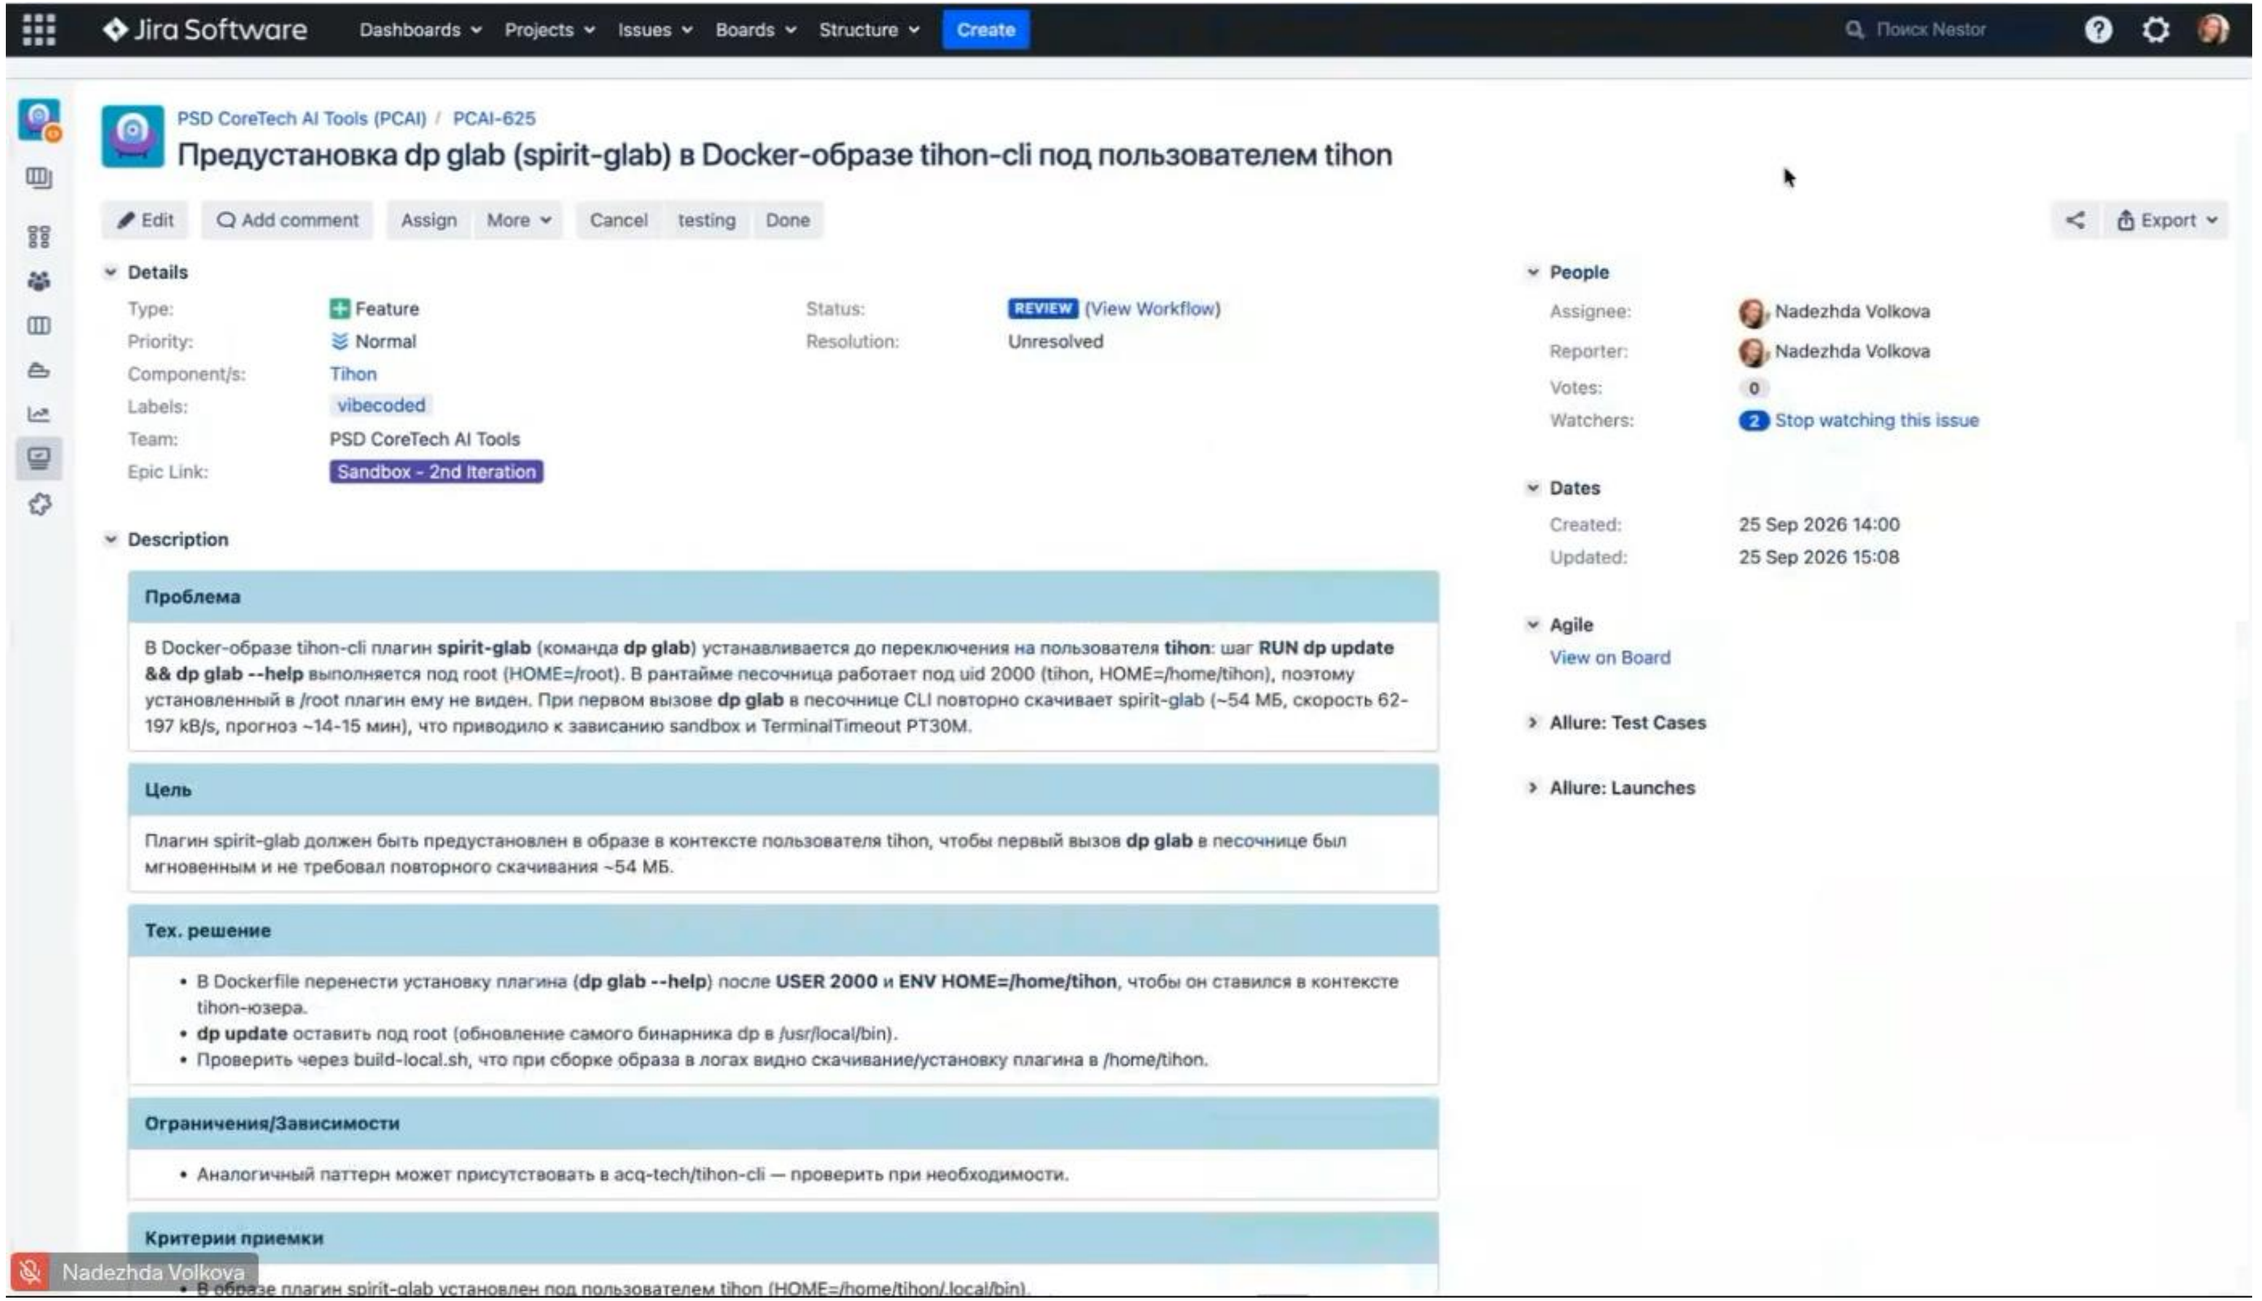
```
@Service
public class IntegrationAuthService {

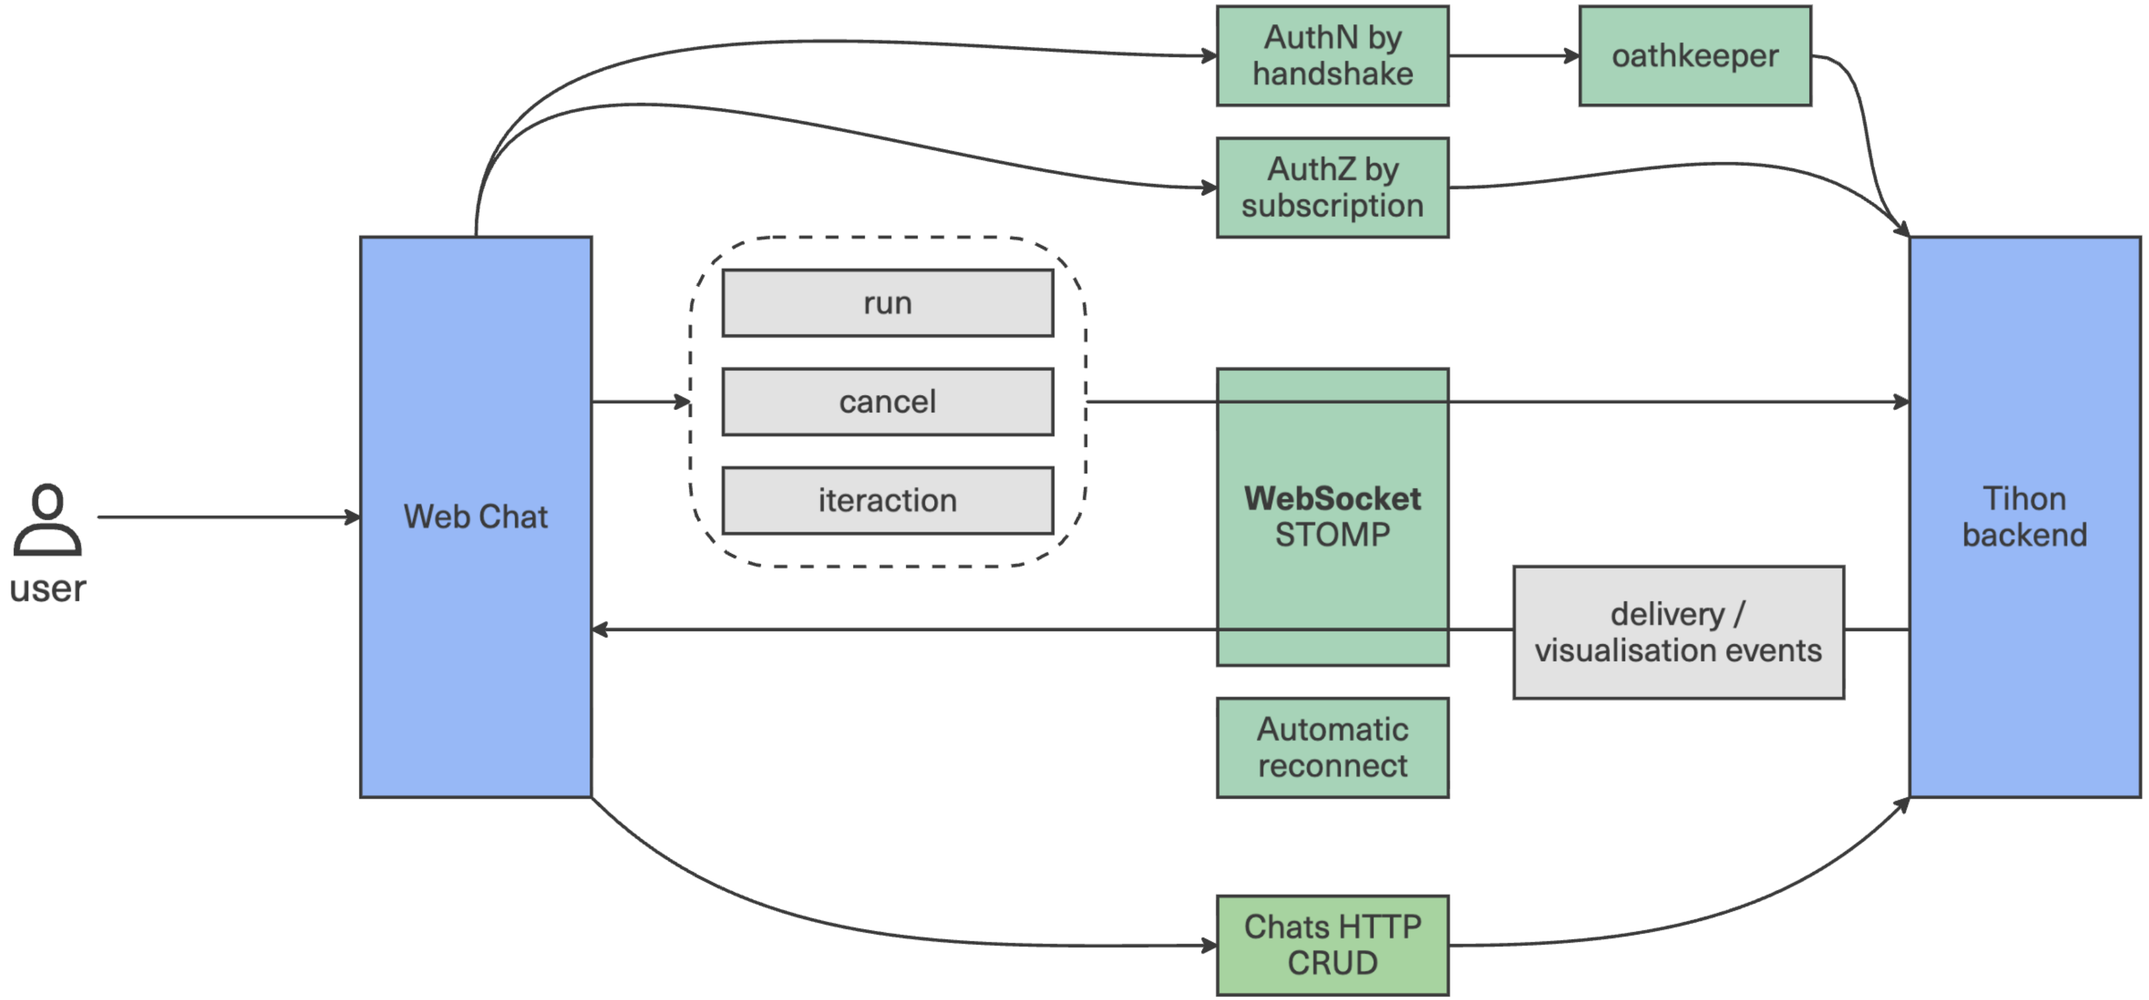
  private final TokenExchangeService tokenService;
  private final UserContextService userContextService;

  private final Cache<String, String> cache
        = Caffeine.newBuilder()
              .maximumSize(10_000)
              .expireAfterWrite(3600, SECONDS)
              .build();

  public String getToken(SystemType systemType) {
   String adLogin = userContextService.getCurrent();
   return cache.get(
              userName + ":" + systemType,
              key -> tokenService.issue(adLogin,
                    systemType.getAudience()));
  }
```

Веб-чат


Jira Software
Dashboards
Projects
Issues
Boards
Structure
Create
Поиск Nestor
PSD CoreTech AI Tools (PCAI) / PCAI-625
Предустановка dp glab (spirit-glab) в Docker-образе tihon-cli под пользователем tihon
Edit
Add comment
Assign
More
Cancel
testing
Done
Export
Details
Type: Feature
Priority: Normal
Component/s: Tihon
Labels: vibecoded
Team: PSD CoreTech AI Tools
Epic Link: Sandbox - 2nd Iteration
Status: REVIEW (View Workflow)
Resolution: Unresolved
People
Assignee: Nadezhda Volkova
Reporter: Nadezhda Volkova
Votes: 0
Watchers: 2 Stop watching this issue
Dates
Created: 25 Sep 2026 14:00
Updated: 25 Sep 2026 15:08
Agile
View on Board
Allure: Test Cases
Allure: Launches
Description
Проблема
В Docker-образе tihon-cli плагин spirit-glab (команда dp glab) устанавливается до переключения на пользователя tihon: шаг RUN dp update && dp glab --help выполняется под root (HOME=/root). В рантайме песочница работает под uid 2000 (tihon, HOME=/home/tihon), поэтому установленный в /root плагин ему не виден. При первом вызове dp glab в песочнице CLI повторно скачивает spirit-glab (~54 МБ, скорость 62-197 kB/s, прогноз ~14-15 мин), что приводило к зависанию sandbox и TerminalTimeout PT30M.
Цель
Плагин spirit-glab должен быть предустановлен в образе в контексте пользователя tihon, чтобы первый вызов dp glab в песочнице был мгновенным и не требовал повторного скачивания ~54 МБ.
Тех. решение
В Dockerfile перенести установку плагина (dp glab --help) после USER 2000 и ENV HOME=/home/tihon, чтобы он ставился в контексте tihon-юзера.
dp update оставить под root (обновление самого бинарника dp в /usr/local/bin).
Проверить через build-local.sh, что при сборке образа в логах видно скачивание/установку плагина в /home/tihon.
Ограничения/Зависимости
Аналогичный паттерн может присутствовать в acq-tech/tihon-cli — проверить при необходимости.
Критерии приемки
В образе плагин spirit-glab установлен под пользователем tihon (HOME=/home/tihon/.local/bin).
Nadezhda Volkova


AuthN by handshake
oathkeeper
AuthZ by subscription
run
cancel
iteraction
Web Chat
WebSocket STOMP
Tihon backend
delivery / visualisation events
Automatic reconnect
Chats HTTP CRUD
user

Итоги

Влияние на метрики команд

До -30% TTM

- На отдельных командах
- Там, где сценарии прижились
- Сильное влияние на «буферные» статусы

Сложно измерить

- ИИ ускоряет уже сильные команды
- Как отделить влияние одного инструмента от другого?
- CSAT – самый надежный feedback

На нашей команде

- ~90% кода пишет ИИ
- Отдельные модули – только ИИ
- Больше не создаем задачи руками
- Lead Time – иногда часы

Сценарии, которые работают

Ответы по документации

Заведение задач

Критерии приемки

Definition of Ready

Definition of Done

Ревью документов

Помощь в канале поддержки

Код-ревью

Автообновление документации

Тестирование API / UI

Исправление по код ревью

Реализация мелких задач

Создание документации

Пошаговая реализация задач

Рутинные конфигурации

Исследования логов

Увеличение покрытия

Чему научились



Магии нет

Open Source – ОК для старта, но если хочешь серьезно – готовься писать агента сам.

Процессы

Вайбкодинг ломает привычные командные процессы, увеличивает разрыв между простыми и сложными задачами.

Human-in-the-loop

Нужен не только для контроля, но и для настройки и обучения инструмента. Полная автоматизация пока не работает.

Т БАНК

Спасибо
за внимание

