podlodka

AI Crew
12 - 16 октября

Мультиагентные системы

Родион Мостовой

AI-архитектор CodeAlive,
автор канала @ai_driven и
OS оркестратора pragmatic-orchestration

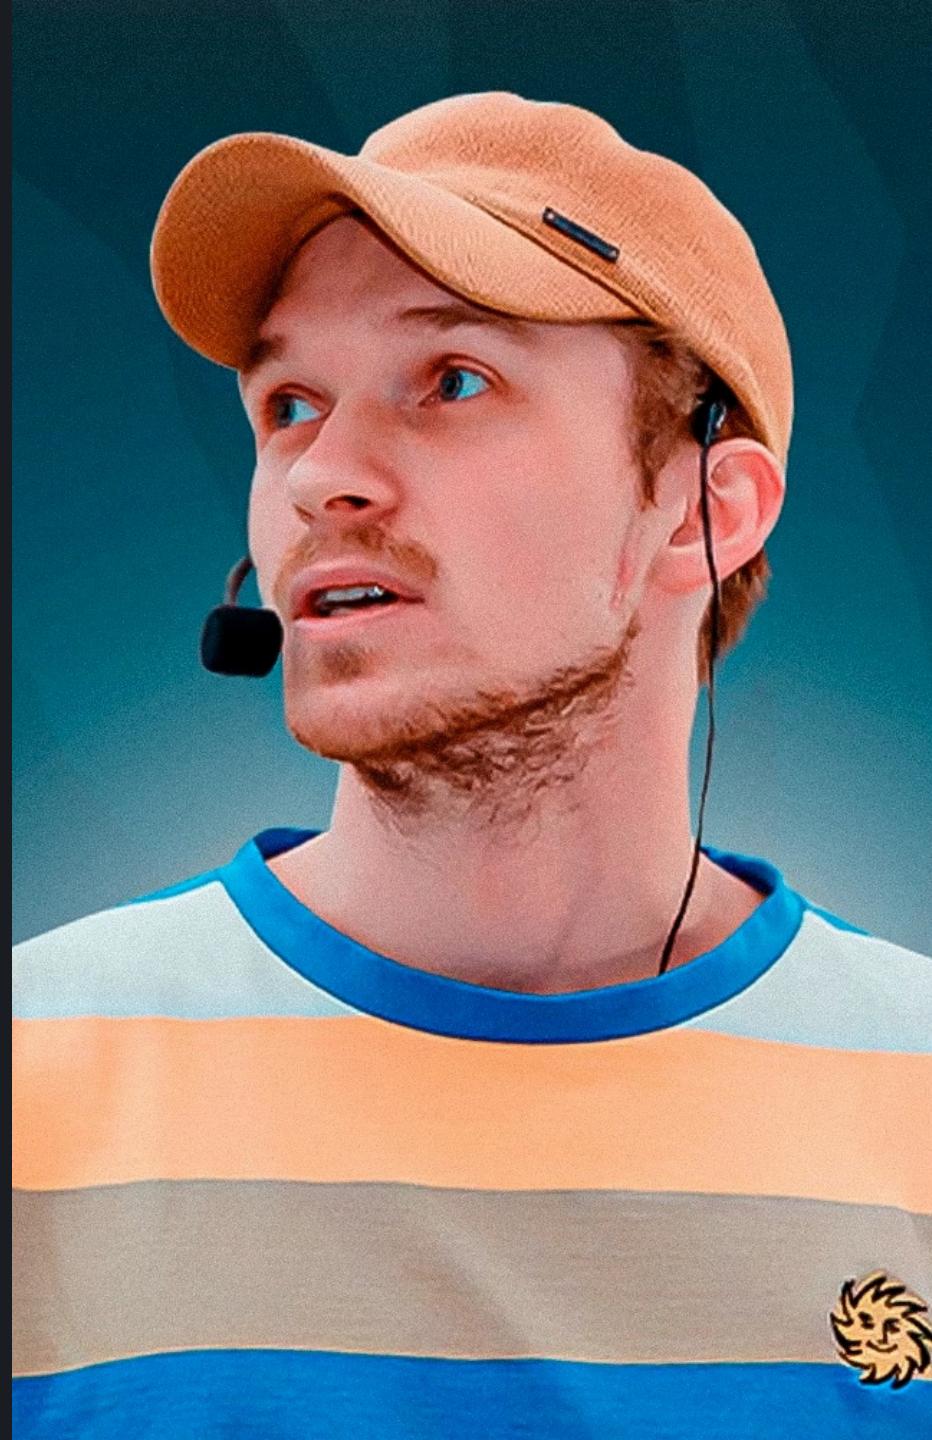
Доклад
Эффективная оркестрация AI-агентов



RWB Selectel

Обо мне

- Работаю .NET разработчиком с 2012 года
- Работал тимлидом в Индид
- Основал 2 стартапа
- Кофаундер и архитектор **CodeAlive**



О чём поговорим

1. Организация команды агентов для автономной работы неделями.
2. Решение проблем, которые на этом пути возникают.
3. Оптимальный выбор моделей и экономия.

Когда нужна команда агентов

Разработка ПО

- Миграция нескольких сервисов
- Большой рефакторинг
- Выполнение эпика
- Приложение под ключ

Интерфейсы для агентов

MCP, скиллы и CLI

Агент-потребитель пробует интерфейс.
По его работе находим проблемы
и дорабатываем инструмент.

Много итераций, есть что делегировать и как проверить результат.

Что обещают вендоры

OpenAI ↗

Codex · 25.06.2026

Самостоятельная работа от минут до часов

Инструменты, взаимодействие со средой и итерации.

Anthropic ↗

Opus 5.5 · сентябрь 2026

Длительные задачи с минимальным надзором

Планирование, субагенты и память между сессиями.

Google ↗

Teamwork · 31.08.2026

Команды агентов работают часами и днями

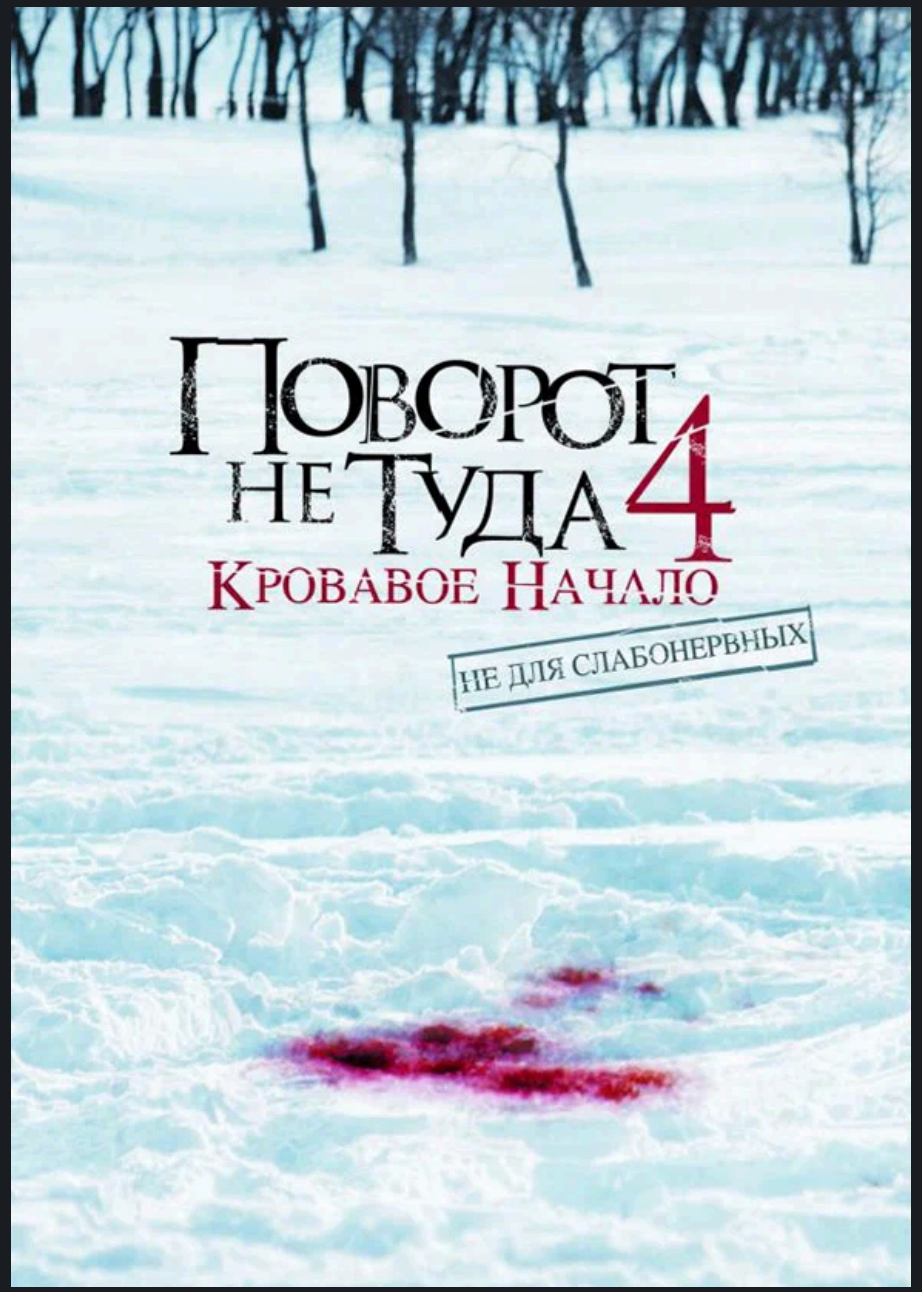
Совместно решают задачу и проверяют друг друга.

Долгая работа не гарантирует результат

Пример: переводим несколько сервисов на новый SDK

Застрял	Часами чинит окружение одного сервиса.
Ушёл в сторону	Переписывает код, который не нужен для миграции.
Обошёл условия	Отключил падающие тесты и отчитался об успехе.

Нужно проверять, приближает ли работа агента к цели.


Поворот не Туда 4
Кровавое Начало
не для слабонервных

Зашоривание: застрял на одном подходе

Снова пробует
тот же путь.

Другой вариант
не рассматривает.



Так может застрять и исполнитель, и координатор.

Бенчмарки длительных задач

Бенчмарк	Задача	Цена попытки
Code Migration	Переписать программу на другом языке	$44,36
ProgramBench	Воссоздать программу по поведению	$42,66
FrontierSWE	Сложные задачи в реальных репозиториях	$98,87
SWE-Marathon	Большие задачи по разработке ПО	$51,84

Модели, результаты и условия замеров ↗

Цены выбранных запусков на 24.09.2026. Модели и условия различаются; подробности по QR.

Задача и проверка результата

Часть 1

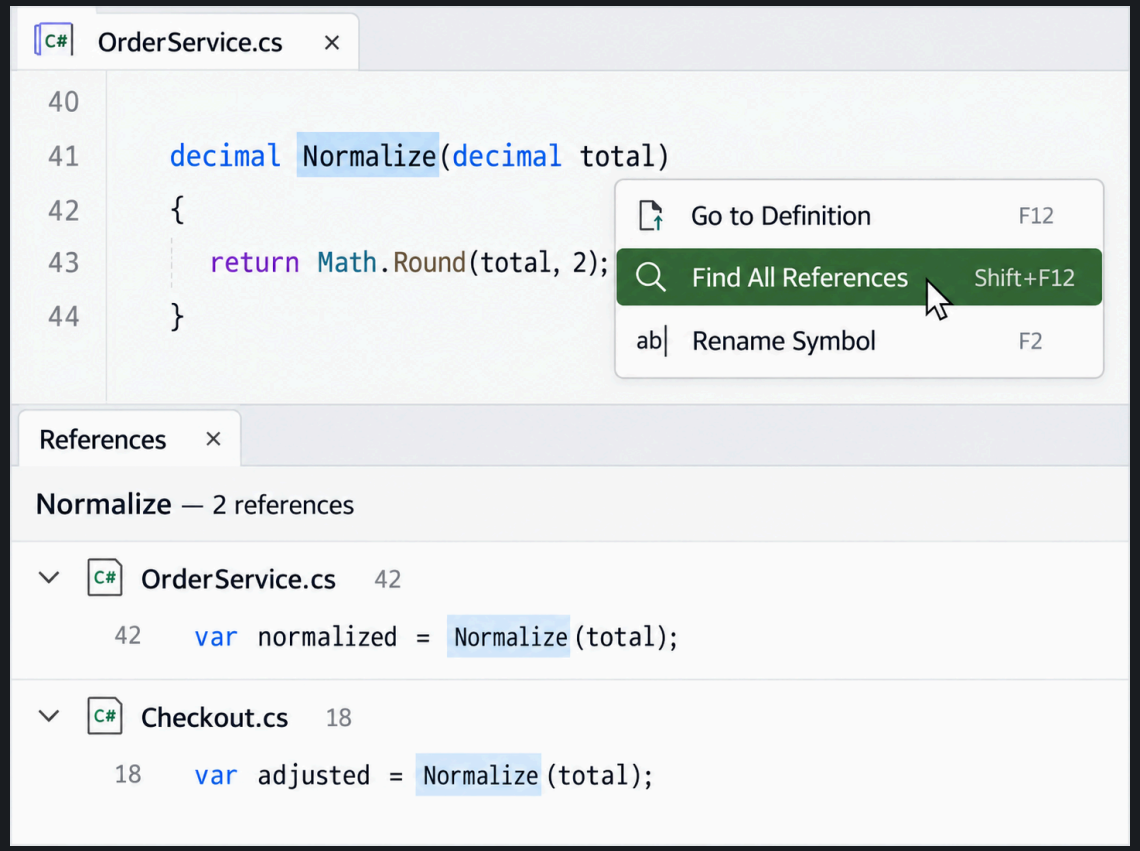
Задача и проверка
Грабли
Автономная работа
Модели и расходы

Дадим агенту навигацию по коду, как в IDE

Мы так делаем каждый день

Переходим к определению.
Находим все вызовы метода.

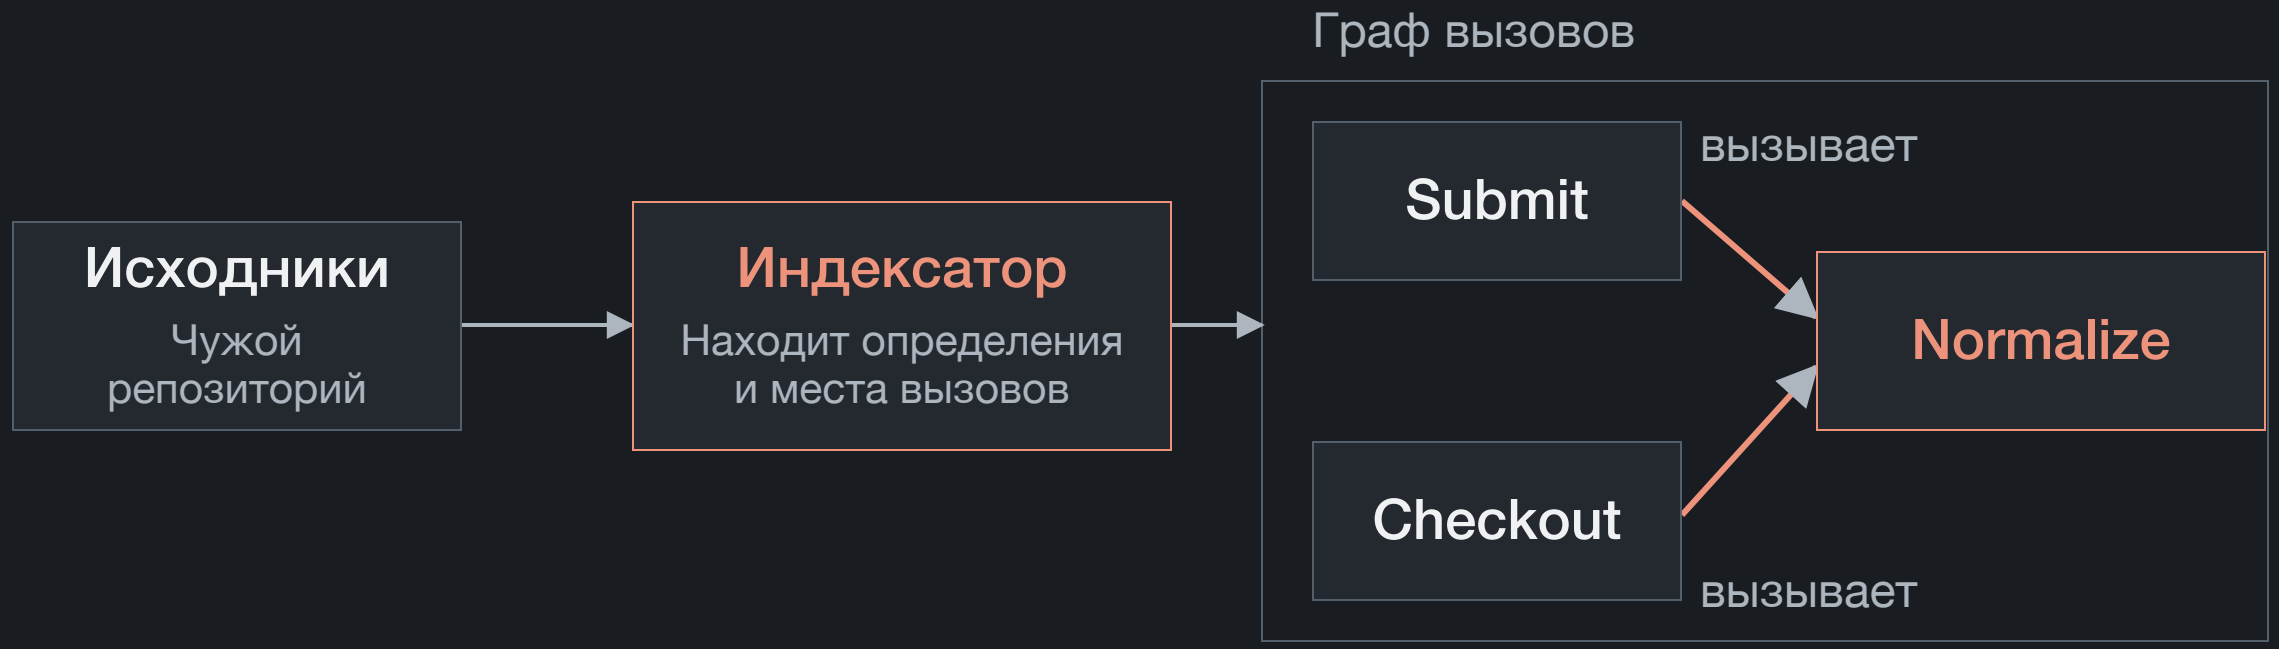
Хотим, чтобы агент тоже мог быстро находить нужный код.



Для этого CodeAlive нужен индекс определений и связей.

Индексатор превращает исходники в связи

Читает исходники и связывает вызовы с определениями методов.



Агент запрашивает связи и открывает нужные исходники.

Почему нужно обойтись без сборки проекта

CodeAlive индексирует чужие репозитории.

Чтобы собрать проект

- Нужные SDK и зависимости
- Настройки окружения
- Запуск build-скриптов

Что требуется от индексатора

- Читать исходники
- Находить определения и связи

> Не требовать успешной сборки
> и не запускать код проекта

Хотим получать связи без настройки сборки каждого репозитория.

Почему понадобился свой индексатор

Слишком долго

Языковой сервер (LSP):
12 часов на Spring Framework

Отдельные запросы занимали минуты.

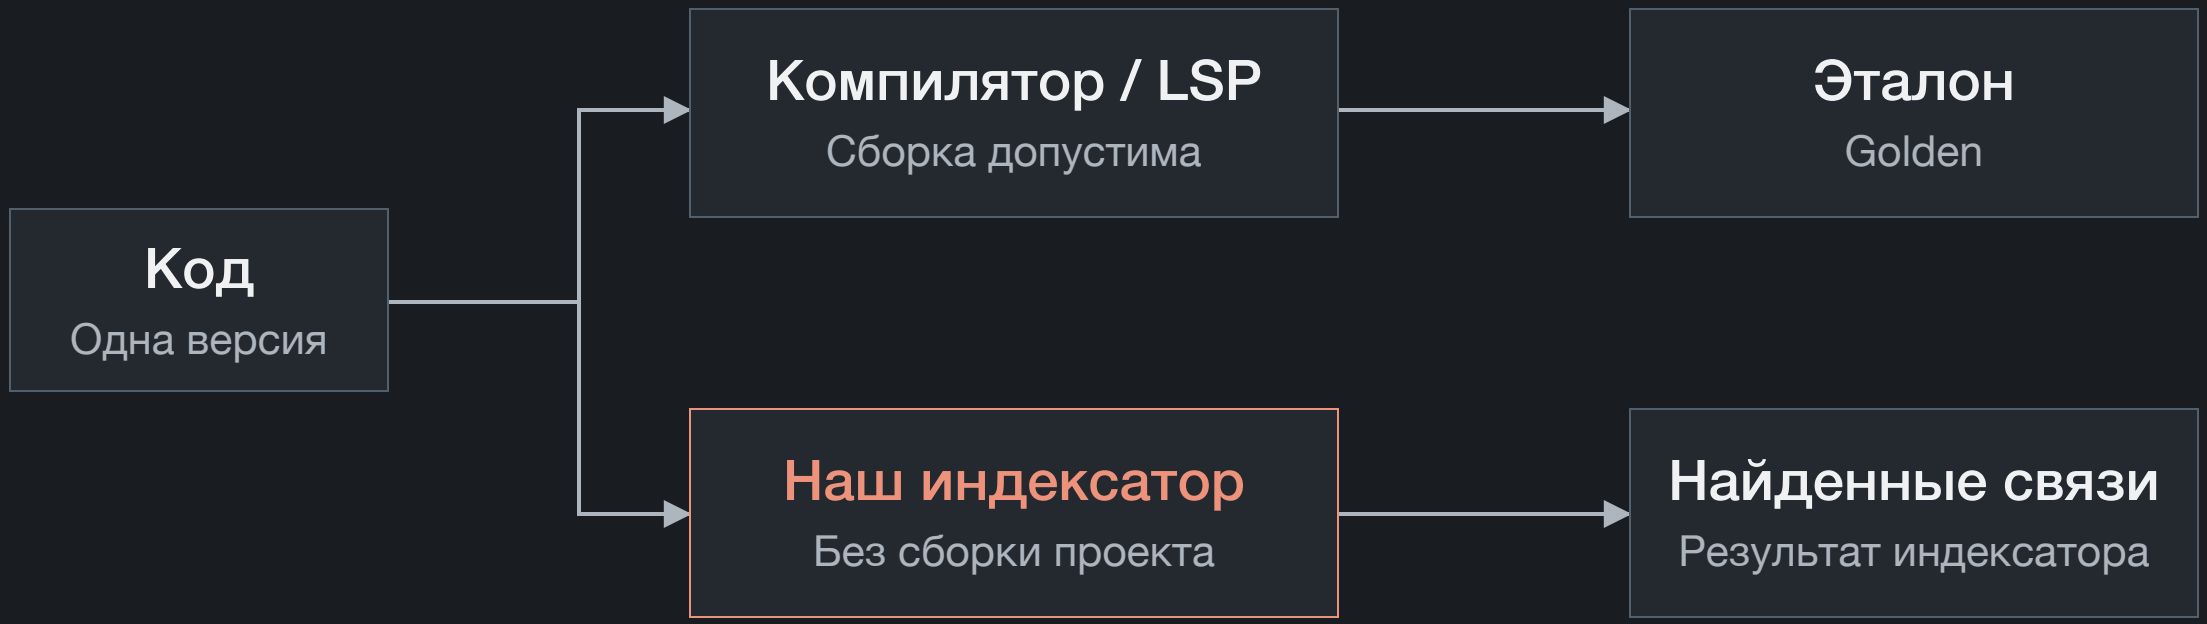
Ошибается в связях

Пропускал вызовы.
Добавлял неверные связи.

Готовый индексатор: проверка
на коде Playwright. Наши замеры.

> Поручили агентам написать свой индексатор.
> Нужна автоматическая проверка качества связей.

С чем сравнивать результат индексатора



Сравниваем связи: что пропущено, что лишнее?

Как измеряем качество индексатора



Precision

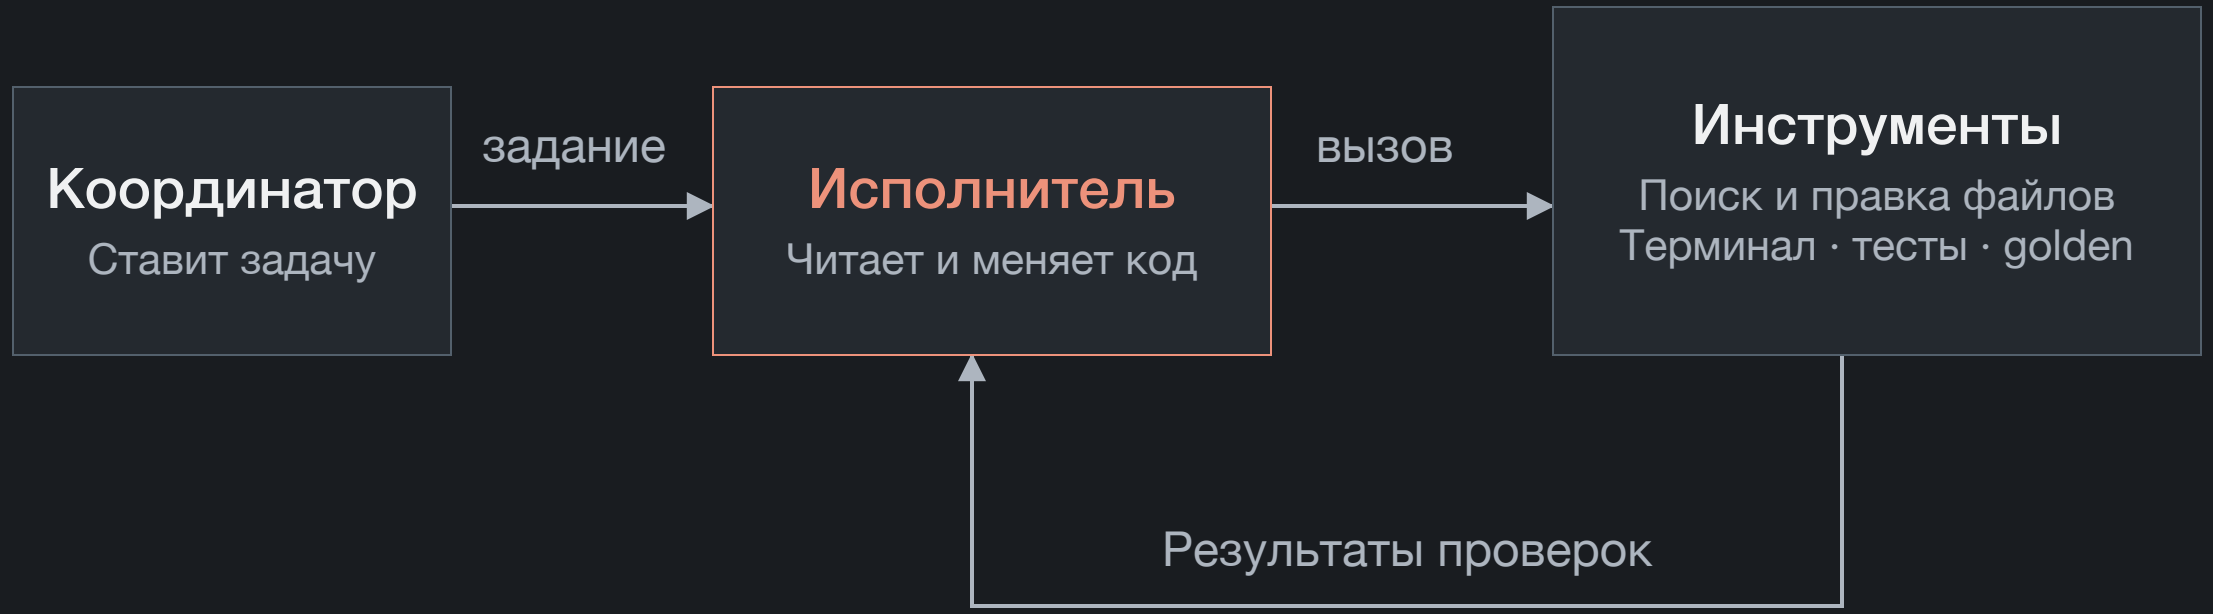
Скольким найденным связям можно доверять?

Recall

Сколько нужных связей мы нашли?

Цель на выбранных проектах: ≥95% по обеим метрикам.

Агент меняет код и проверяет результат

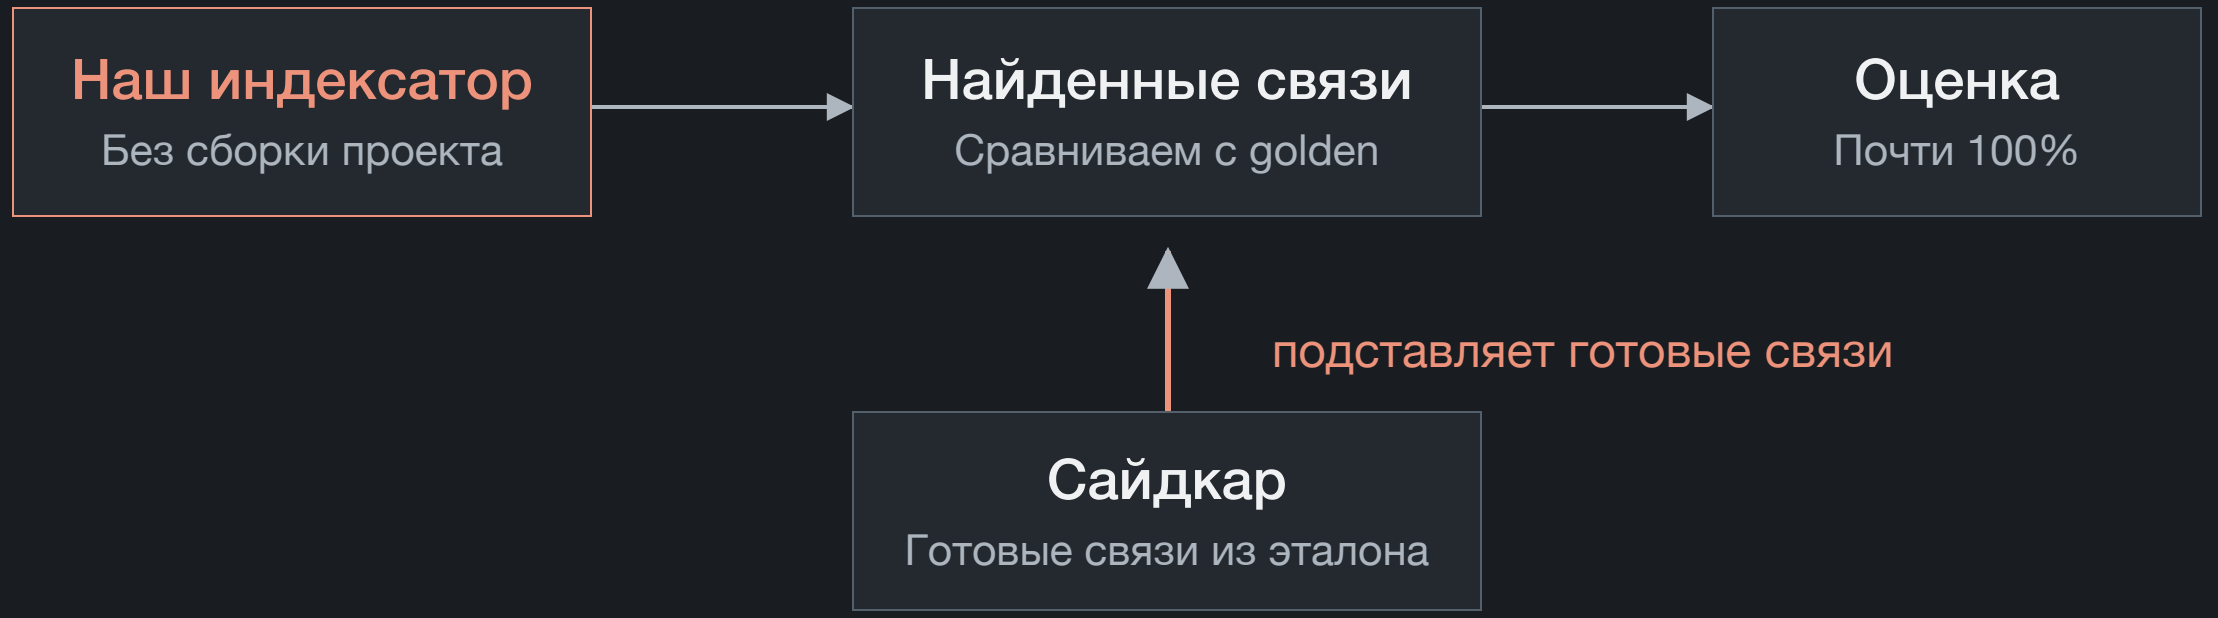


Расхождения → исправление → повторная проверка

Грабли и как с ними справляться

Часть 2

Как получились почти 100%?



Оценка выросла. Требование «без сборки» нарушено.

Как бороться с reward hacking

Задать цель и ограничения	Например: находить связи без сборки проекта.
Предусмотреть обходы	Спросить модели о лазейках и явно запретить их.
Проверить, как получен результат	Проверить код, источники данных и исключённые тесты.

Застряли на сборке одного проекта

Около полудня
на сборку.

Индексатор так
и не улучшили.

Подготовка проекта для
golden
(время по памяти)



Что можно сделать, пока эта сборка не работает?

Проверяем исполнителя сразу после запуска

Что увидели

Исполнитель опять настраивает сборку

→

Что написали

«Вернись к коду. Сборку отложи»

→

Что проверили

Исполнитель вернулся к коду индексатора

Первая проверка: через минуту · Потом: каждые 5–15 минут

Steer: сообщение исполнителю, пока он работает.

Пример вмешательства

Исполнитель ведёт журнал отклонений

Пример записи

Ожидал	Подготовить проект для golden.
Обнаружил	Сборка упёрлась в зависимости.
Предлагаю	Пока проверять готовые проекты; к этому вернуться.
Риск	Этот проект ещё не проверен.

Координатор читает журнал и решает, что менять в плане.

Организация автономной работы

Часть 3

Роли в «оркестре»



Сначала — брейнсторминг и план

Сильная модель: Fable или Astra

Обсуждаем подход

Изучаем код и ограничения.
Сравниваем варианты решения.

→

Фиксируем в спеке

Цель и ограничения.
Шаги и критерии приёмки.

Из плана — задания исполнителям

Исправить пропущенную связь.

Проверка: связь найдена, остальные тесты проходят.

Goal: работать, пока задача не решена



Большой расход токенов

Координатор тоже зашоривается

По расписанию: экономим лимиты



Читает файл состояния

0 мин | 30 мин | 60 мин

Существенно экономит лимиты, но не спасает от зашоривания.

Аудитор проверяет, не застрял ли координатор



Задача аудитора — посмотреть со стороны и предложить другой подход.

Ultra: поручить всё самой сильной модели



Проще запустить, но дорого. И модель тоже может зациклиться.

Как не потерять прогресс между сессиями

Старая сессия
Перезапуск или сжатие контекста

↓

Файл состояния

↓

Новая сессия

Что координатор сохраняет

- Цель и ограничения
- Что сделано и что не работает
- Что пробовали и почему не помогло
- Что делать дальше и кто сейчас работает

Новая сессия читает файл и продолжает работу.

Почему я ограничиваю контекст координатора

Поиск нужных сведений в длинном контексте



Прогресс сохраняем в файл.

Мой ориентир:
до 300k токенов
в контексте.

Context Arena v2 · GPT-5.6 Sol (max), MRCRv2, 8 needles · снимок 24.09.2026. MRCR измеряет работу с информацией в контексте, не качество оркестрации.

Запуск внешних агентов через Porch

Другие модели и лимиты через привычного агента.

Ваш агент

Координатор

→

Porch

CLI + скилл

→

Внешние агенты

Claude Code, Codex
OpenCode, Devin
Grok Build

`claude -p`
`codex exec`

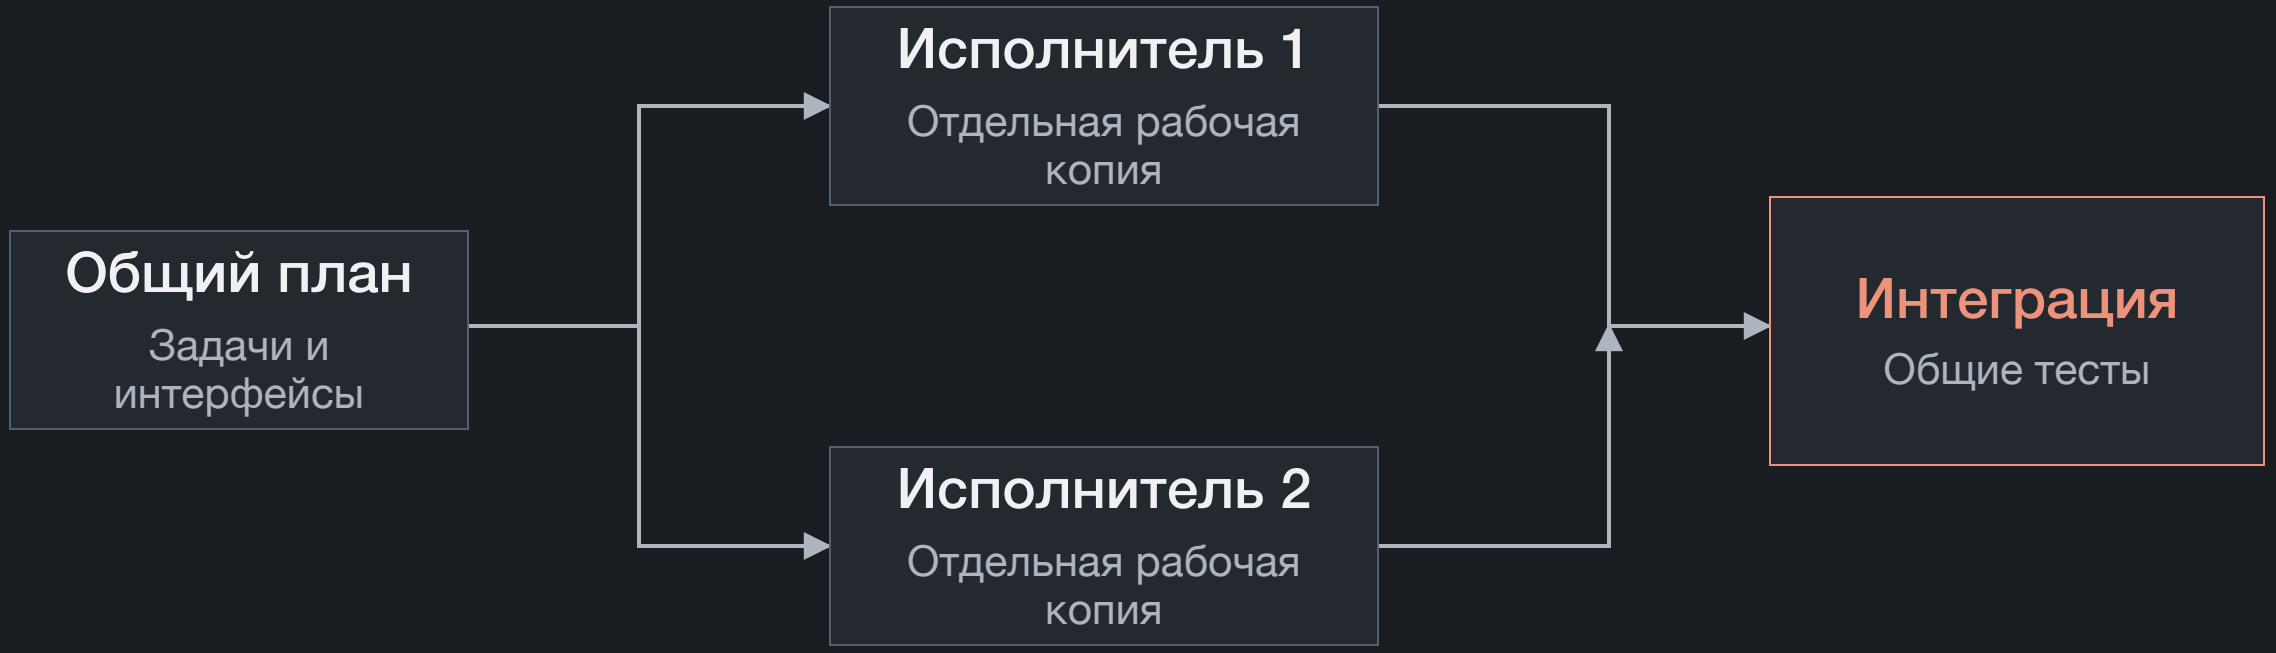
Разовый запуск через CLI

`ACP`

Agent Client Protocol
Например, адаптер Devin

Porch
Код и скилл ↗

Как объединить работу нескольких агентов



Нет конфликтов в файлах ≠ всё работает вместе.

Запускаем агентов на удалённой машине

Долгие прогоны и тяжёлые сборки — вне рабочего ноутбука.

Координатор

Рабочая машина

SSH →

VM: Linux / Windows

Porch и исполнители

Рабочие копии

Индексация и проверки

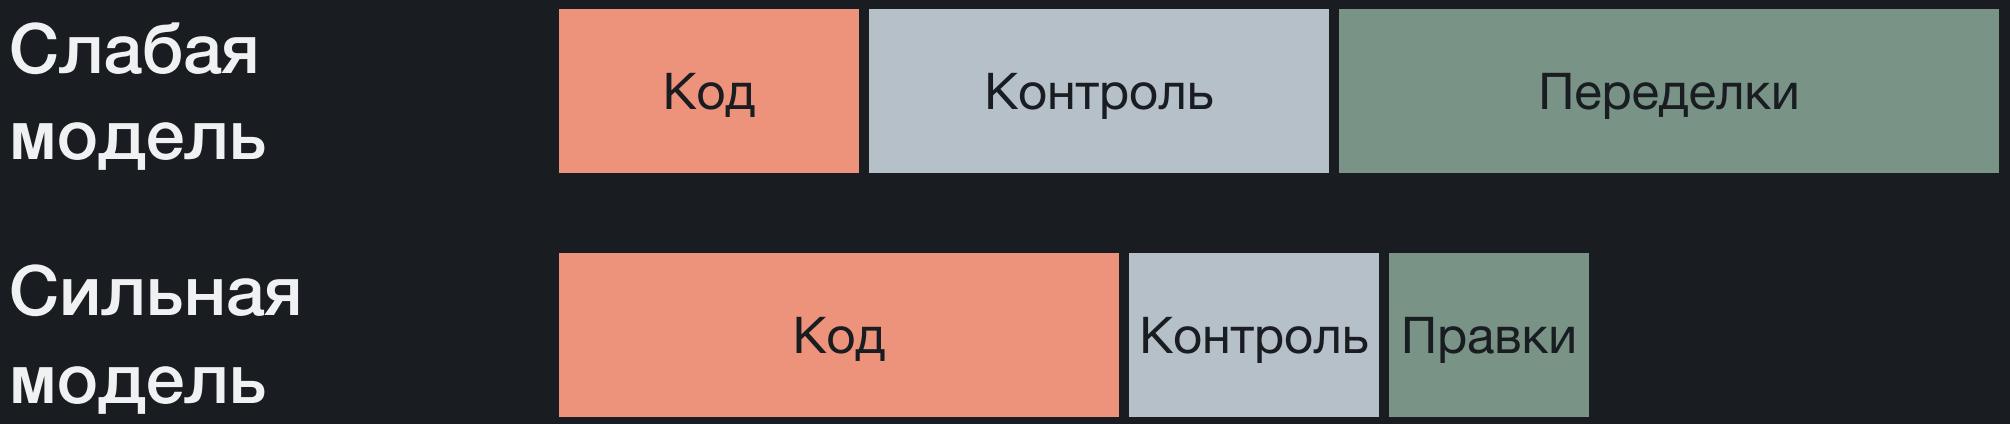
> Граница изоляции: VM и учётная запись.
> Рабочая папка сама по себе не sandbox.

Модели и расходы

Часть 4

Дешёвый исполнитель может обойтись дороже

Условная схема расходов



За слабым исполнителем координатору приходится переделывать.

Кому писать код, а кому изучать проект

Писать и исправлять

Сильная модель

Например, Opus low
или GPT-6 Sol low

Изучать кодовую базу

GPT-6 Luna

Разбирает разные части проекта
и возвращает ссылки на код.

Luna беру для исследования. Код поручаю более сильной модели.

Что получилось

Индексатор создан

Агенты писали код
и проверяли его по эталону

Остались ошибки.
95/95 для всех языков не подтверждено.

Около месяца

работы с перерывами

≈300 тыс.

строк Python-кода

Включая тесты и инструменты.
Сам сервис: ≈92 тыс. строк.

Без пустых строк, комментариев
и docstring. Версия на 12.10.2026.

Сколько ушло токенов

Codex

8,10 млрд

GPT-5.6 Sol	3,64 млрд
GPT-5.6 Terra	3,16 млрд
GPT-5.5	1,21 млрд
Luna + без модели в логе	88 млн

Claude Code

2,48 млрд

Opus 4.8: 2,37 млрд.
Остальные модели: 119 млн.

Всего: 10,58 млрд
по подтверждённым сессиям.

С учётом повторного чтения кеша. Codex: 16.06–27.07; Claude Code: 05.05–01.08.2026.
Учтена подтверждённая часть работы; это расход токенов, а не сумма платежей.

Выводы

До долгого запуска	План, проверка результата и файл состояния.
От зашоривания	Аудитор со свежим контекстом.
Для экономии	Запуск по расписанию и подходящие модели.

Контакты

Спасибо за внимание

Больше про AI-Driven development, агентов и инженерные практики: в Telegram-канале.

`@ai_driven`

Скиллы, шаблоны и источники доклада ↗

